Université Paris Nanterre

RAPPORT DE STAGE

Manon MOULIN

Master Traitement Automatique des Langues
2025 -2026

Traitement automatique de l'oral - Conception d'un modèle de transcription phonétique en API pour l'occitan



Stage réalisé dans le cadre du projet TARTOAS

Encadrant: Yoann Dupont
Tuteur universitaire: Iris Eshkol-Taravella

Résumé

Ce rapport relate un stage de traitement automatique de l'oral effectué au laboratoire LATTICE, au sein du projet TARTOAS (Traitement Automatique des langues Régionales: Transcription de l'Oral et Annotation Syntaxique). Le but de ce projet est de constituer et enrichir des corpus de langues régionales de France, et de développer des outils adaptés à leur traitement automatique. Le sujet de ce stage est la conception ou l'adaptation d'un modèle de transcription de l'occitan oral vers l'API (alphabet phonétique international).

Mots-clés: traitement de l'oral, phonétique, occitan, langues peu dotées, apprentissage artificiel, TAL

Abstract

This report describes an internship in oral language processing within the LATTICE laboratory, as part of the TARTOAS project. The goal of this project is to create and enrich corpora for regional, low-resource languages from France, and to develop tools adapted to their automatic processing. The goal of the missions completed during this internship was to develop or adapt a model to transcribe audio documents into the IPA (International Phonetic Alphabet).

Keywords: oral processing, phonetics, Occitan, low-resource languages, machine learning, NLP

Remerciements

Le travail décrit dans ce rapport n'aurait pu être effectué sans l'aide de plusieurs personnes, que j'aimerais remercier. Je tiens tout d'abord à remercier l'ensemble des membres du Lattice pour leur accueil au cours de ces cinq mois de stage. Je remercie en particulier Madame Sophie Prévost, directrice du laboratoire, de m'avoir permis d'effectuer ce stage au sein de cette équipe de recherche. Je remercie également Pierre M., encadrant dans l'équipe ERTIM et responsable du projet dans lequel s'inscrivait ce stage, pour sa confiance.

Je tiens à adresser mes sincères remerciements à mes encadrants au Lattice, Yoann Dupont et Mathieu Dehouck, pour leur bienveillance et la qualité de leur suivi. Leur conseils et leur accompagnement m'ont aidée à prendre confiance et à progresser tout au long du stage. Je remercie également Iris Eshkol-Taravella, mon enseignante référente à l'université, pour son suivi au long de cette expérience.

Je souhaite enfin remercier les membres de l'équipe du Lattice pour leur accueil chaleureux et les échanges que nous avons partagés. J'adresse également une pensée particulière à mes proches et à mes camarades de promotion pour leur soutien, leurs encouragements et leur présence tout au long de cette année.

Résumé....1
Abstract....1
Remerciements....2
Introduction....5
1. Contexte du stage....6
1.1. Contexte de travail....6
1.1.1. Présentation du laboratoire....6
1.1.2. Présentation du projet....6
1.2. Présentation du sujet de stage....7
1.2.1. Objectifs et missions....7
1.2.2. Intérêt du sujet....7
1.2.3. Enjeux et problématiques principales....8
1.3. Cadre théorique et état de l'art....9
1.3.1. ASR et langues peu dotées....9
1.3.2. Vers la transcription phonétique....11
2. Collecte des données....12
2.1. Conditions générales pour la constitution du corpus....12
2.2.1. CommonVoice....12
2.2.2. OcOr....14
2.2.3. Chants....15
2.2.4. Occiton2....16
2.3. Les données de référence....17
2.3.1. Phonétisation avec Lo Congrès....17
2.3.2. Difficultés et solutions adoptées....18
3. Mise en place du pipeline de transcription automatique....19
3.1. Outils et bibliothèques utilisés....19
3.2.1. Entraînement....20
3.2.2. Pipeline de test du modèle....20
3.3. Stratégies d'alignement avec la référence....21
3.3.1. Distance de Levenshtein....21
3.3.2. Analyse phonétique avec PanPhon....22
4. Expériences et évaluation....23
4.1. Préparation des données pour l'évaluation....23
4.1.1. Nettoyage....23
4.1.2. Récupération des références....24
4.1.3. Application de l'alignement....25
4.2. Métriques d'évaluation....25
4.2.1. Phoneme Error Rate (PER)....25
4.2.2. Phonological Feature Error Rate (PFER)....26
4.3. Expériences et résultats....26
4.3.1. Évaluation des prédictions....26
4.3.2. Analyse des représentations internes....35
Conclusion et discussions....40
Bibliographie....43

Annexes..... 45

Introduction

Les langues peu dotées constituent actuellement un défi pour le traitement automatique des langues, et notamment pour les technologies d'ASR (Automatic Speech Recognition, reconnaissance automatique de la parole), pour plusieurs raisons. Le manque de ressources ainsi que le faible taux de locuteurs limitent souvent le développement d'outils de TAL performants. En général, même les outils qui affirment prendre en charge toutes les langues ne sont pas adaptés aux langues peu dotées. L'occitan, langue régionale parlée dans le sud de la France, est un exemple qui illustre ces difficultés. Sa forte variabilité linguistique et la rareté de ses données disponibles rendent la création d'outils automatiques difficile. Cependant, des travaux sont en cours pour inclure les langues peu dotées dans les outils modernes de TAL, et c'est dans cet objectif que s'inscrit le stage relaté dans ce rapport. L'objectif principal du stage était de récolter des données et d'explorer les possibilités d'adaptation de modèles de transcription de l'oral à l'occitan.

Note : dans un souci de fluidité de la rédaction, ce rapport emploie en grande partie le pronom "nous" académique. Ce choix relève d'une convention d'écriture et ne reflète pas le nombre de personnes impliquées dans les tâches effectuées. Lorsque certaines tâches ont été réalisées conjointement avec les encadrants, cela sera indiqué explicitement.

Ce rapport est organisé comme suit : dans un premier temps, nous présenterons le contexte du stage (présentation de l'environnement de travail, du projet, des objectifs et des missions réalisées, cadre théorique et état de l'art). Dans un second temps, nous présenterons les données récoltées et utilisées tout au long du stage (conditions et processus de constitution du corpus, les différentes sources, données de référence). Dans une troisième partie, nous présenterons le processus de mise en place du pipeline de test d'un modèle de transcription automatique (outils utilisés, le modèle, test et alignement). Enfin, nous reviendrons sur l'évaluation du modèle (préparation des données, métriques d'évaluation utilisées, expériences et résultats). Nous terminerons par une conclusion et une discussion des pistes futures.

1. Contexte du stage

1.1. Contexte de travail

1.1.1. Présentation du laboratoire

Le Lattice (Langue, Textes, Traitements Informatiques, Cognition) est un laboratoire d'enseignement et de recherche du CNRS, rattaché à l'ENS PSL (Paris Sciences et Lettres) et à l'Université Sorbonne Nouvelle - Paris 3. Il regroupe notamment des chercheurs du CNRS et des enseignants-chercheurs de l'Université Sorbonne Nouvelle ou d'autres universités. Les recherches du Lattice portent sur la linguistique et le traitement automatique des langues. Les domaines de recherche du laboratoire s'articulent autour de 4 axes thématiques :



FIGURE 1 - *Les 4 axes de recherche du Lattice*[1]

1.1.2. Présentation du projet

Le projet TARTOAS (Traitement Automatique des langues Régionales : Transcription de l'Oral et Annotation Syntaxique), dans le cadre duquel prend place le stage décrit dans ce rapport, est un projet mené conjointement par le LATTICE, le LPP (Laboratoire de Phonétique et Phonologie) et l'équipe ERTIM de l'INALCO. Il vise à constituer et enrichir des corpus oraux pour des langues régionales de France (wallon, picard, paicî, occitan), et à

[1] https://www.lattice.cnrs.fr/la-recherche/

développer des outils adaptés à leur traitement automatique.[2] Parmi les objectifs du projet TARTOAS, on compte, en plus de la constitution et l'enrichissement de corpus, l'étude des différences entre les formes orales et écrites des langues régionales, l'étude des structures grammaticales de ces langues, et l'étude du rôle du contact entre ces langues dans les variations linguistiques.

1.2. Présentation du sujet de stage

1.2.1. Objectifs et missions

L'objectif dans lequel s'inscrit ce stage est la conception ou l'adaptation d'un modèle de transcription phonétique en alphabet phonétique international (API) pour l'occitan. Le but principal du stage est d'estimer l'utilisabilité des outils dans leur état actuel et de fournir des données supplémentaires pour leur entraînement et leur évaluation. Les missions qui m'ont été confiées lors de ce stage étaient variées. Parmi les missions principales figurent la collecte de données, la recherche et le test d'un modèle de transcription phonétique, ainsi que son évaluation. J'ai commencé le stage par l'établissement d'un état de l'art, afin d'avoir une base de travail et de déterminer quels outils utiliser. J'ai également été amenée à faire du tri et du nettoyage de données, ainsi qu'à tester différentes stratégies d'alignement, et enfin, à établir une pipeline de traitement et de test des données et du modèle. Une grande partie de mon stage a été consacrée à tester un modèle de transcription phonétique et à mener différentes expériences afin de l'évaluer et de comprendre comment l'adapter à l'occitan. L'une des applications envisagées à terme pour un tel outil serait l'assistance dans l'apprentissage et l'entraînement à la prononciation de l'occitan pour des apprenant·e·s de la langue.

1.2.2. Intérêt du sujet

On peut se demander quelle est l'utilité de mettre en place des outils de TAL en occitan, puisqu'a priori tous les locuteurs de l'occitan, ou en tout cas la grande majorité, parlent également français. À première vue, on pourrait donc penser que ce n'est pas vraiment "utile", d'autant plus que les outils de TAL sont en général très performants sur le français. Cependant, une langue n'est pas seulement un outil de communication dont le but ne serait que pratique. Une langue est aussi porteuse d'un patrimoine et de l'identité culturelle de ses locuteurs, un symbole d'appartenance à une communauté. De plus, selon *l'Atlas of the*

[2] Sorbonne Alliance, https://sorbonne-alliance.pantheonsorbonne.fr/recherche/laureats

World's Languages in Danger de l'UNESCO, l'occitan figure parmi les langues menacées. Mettre en place des outils de TAL prenant en charge l'occitan peut donc contribuer à créer des conditions favorables pour aider les locuteurs à garder leur langue vivante, et à l'utiliser au quotidien.

D'un point de vue linguistique, un modèle de transcription automatique permettrait de faciliter la création de corpus annotés, et donc d'améliorer les recherches en linguistique comparative, notamment sur les différences entre les formes orales et écrites des langues régionales (l'un des objectifs du projet TARTOAS).[3] D'un point de vue didactique, il est important de disposer de ressources fiables pour pouvoir apprendre une langue. Enrichir des corpus et entraîner des modèles performants est donc un avantage non négligeable pour que la langue puisse être apprise correctement.

L'intérêt de notre sujet réside également dans le fait qu'il traite d'un domaine du TAL en pleine expansion : la reconnaissance automatique de la parole (ASR). Tester des modèles d'ASR sur des langues peu dotées peut permettre d'aller plus loin en mettant en lumière des limites et en tentant de les résoudre. Les corpus oraux sont encore un défi en TAL, il est donc toujours pertinent de s'y intéresser.

1.2.3. Enjeux et problématiques principales

L'un des premiers enjeux auxquels nous serons confrontés dans l'élaboration d'outils d'ASR pour l'occitan est le manque de données. C'est pourquoi l'une des problématiques du projet est la constitution de corpus. Une autre des problématiques principales de ce stage sera de savoir à quel point un modèle de transcription phonétique entraîné sur plusieurs langues est utilisable sur une langue peu dotée comme l'occitan, si le modèle ne l'a jamais vue. Nous tâcherons de comprendre comment les performances du modèle peuvent être améliorées, et si du fine-tuning est nécessaire pour qu'il soit adapté à l'occitan.

[3] Sorbonne Alliance, https://sorbonne-alliance.pantheonsorbonne.fr/recherche/laureats

1.3. Cadre théorique et état de l'art

1.3.1. ASR et langues peu dotées

Les premiers jours du stage ont été consacrés à l'établissement d'un état de l'art, afin d'avoir une base théorique. Le travail réalisé au cours de ce stage s'inscrit dans la continuité d'autres travaux menés dans les domaines de la reconnaissance automatique de la parole (ASR) et du traitement des langues peu dotées.

Les systèmes d'ASR actuels sont en général très performants sur les langues pour lesquelles on dispose d'une grande quantité de données annotées. Cette dépendance à de grands corpus constitue une limite, en particulier lorsqu'il s'agit d'adapter des systèmes d'ASR à des langues peu dotées pour lesquelles, par définition, on ne dispose que d'une quantité réduite de données annotées. Des travaux récents se sont donc intéressés à ce problème et ont cherché des méthodes qui permettraient de réduire le besoin en quantité de données annotées. Le modèle Wav2vec 2.0 proposé par Baevski et al en 2020 est notamment une référence dans le domaine.[4] L'approche utilisée pour entraîner ce modèle marque une transition par rapport aux modèles d'ASR précédents, en ce que l'entraînement de Wav2vec 2.0 ne nécessite pas de grandes quantités de données audios annotées. Le modèle est entraîné par apprentissage auto-supervisé sur des données non annotées, à partir desquelles il apprend des représentations acoustiques de la parole. Il est ensuite fine-tuné sur une plus petite quantité de données annotées. Cette approche est particulièrement intéressante pour les langues peu dotées, car elle montre qu'il n'est pas essentiel d'avoir une grande quantité de données annotées pour obtenir de bons résultats. Wav2vec 2.0 rend possible l'implémentation de systèmes d'ASR pour des langues dans lesquelles on ne dispose que d'une quantité réduite de données annotées. En effet, les résultats du modèle atteignent voire dépassent les performances des modèles d'ASR entraînés sur des grandes quantités de données annotées, bien qu'il soit entraîné sur environ cent fois moins de données annotées. L'apparition du modèle Wav2vec 2.0 a donné lieu au développement de plusieurs modèles dérivés, parmi lesquels figure Wav2Vec2Phoneme, qui propose une adaptation du modèle à la transcription phonétique, et qui servira de base expérimentale lors de ce stage.

[4] Baevski Alexei, Zhou Henry, Mohamed AbdelRahman, Auli Michael, *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representation*

Dans le cas de l'occitan, les travaux sont encore peu nombreux. Un article de I. Morcillo et al (2024) relate une étude sur l'ASR pour l'occitan, et en particulier pour les variantes gasconne et languedocienne. Selon les auteurs, il existait déjà des outils de TAL pour l'occitan en 2024, comme notamment un conjugueur de verbes, un correcteur orthographique, des plateformes de traduction automatique ou encore des technologies de text-to-speech. Cependant, aucun modèle d'ASR entraîné pour l'occitan n'avait encore été mis en place. L'article présente donc le premier système d'ASR pour l'occitan, basé sur le fine-tuning du modèle Whisper (Radford et al., 2023), pré-entraîné sur 680h de données audio. Les difficultés rencontrées dans cette tâche sont principalement la variabilité de la langue et le manque de données. En effet, il existe six variantes d'occitan qui ont toutes des règles de prononciation différentes. Bien que l'article ne se concentre que sur deux variantes (gascon et languedocien), les auteurs sont confrontés à une grande diversité intra-dialectale, qui pose donc un premier problème pour la reconnaissance des mots. Par exemple, le mot "braveja" ("il se vante") peut être prononcé de toutes les manières suivantes : bra/'ved/zɔ; /bra/'βe/ʒɔ; /bra/'ve/dʒɔ; /bra/'βe/dʒɔ; /bra/'βe/tsɔ; /bʁa/'ve/dʒɔ; /bʁa/'ved/za; /bra/'βe/jɔ; /bra/'βe/jœ; /bra/'βœ/ʒœ; /bra/'βœ/jœ; /bra/'wœ/ʒœ; /bra/'wœ/jœ/. (Morcillo et al., 2024) Cela complique la tâche pour les modèles, qui doivent être capables de reconnaître toutes les réalisations d'un même mot pour être parfaitement efficaces. Le deuxième problème principal est le manque de données orales. Les chercheurs ont dû constituer leur propre corpus oral, notamment en créant une plateforme participative pour permettre à des locuteurs occitans de s'enregistrer. Le corpus écrit, utilisé pour entraîner les modèles de langage qui permettent d'avoir une prédiction plus précise, était aussi trop petit pour les besoins des chercheurs, qui ont décidé de l'augmenter grâce à un système de traduction automatique du français vers l'occitan. En conséquence, les chercheurs se sont heurtés à un problème de qualité des données : les données augmentées automatiquement n'étaient pas toujours de qualité fiable, contenant parfois des erreurs de conjugaison, etc. La faible qualité des données peut biaiser les modèles, voire dégrader leurs performances si les erreurs sont trop fréquentes. Une correction manuelle a donc été nécessaire avant de pouvoir utiliser les données générées. Malgré ces difficultés, l'article montre qu'il est possible d'adapter des systèmes d'ASR à l'occitan et d'obtenir des résultats encourageants.

1.3.2. Vers la transcription phonétique

Le domaine de la transcription de l'oral vers l'API a également fait l'objet d'avancées récentes. Une approche multilingue est proposée par (Taguchi et al., 2023), avec la mise en place du modèle MultIPA. La particularité de leur approche est que l'objectif est d'avoir un modèle universel, capable de produire des transcriptions en API dans toutes les langues. MultIPA est basé sur l'architecture pré-entraînée de wav2vec 2.0. Contrairement au modèle de transcription phonétique précédent, MultIPA est entraîné sur un corpus de plus petite taille, mais pour lequel l'accent est mis sur la qualité. Les données audios utilisées pour l'entraînement sont toutes extraites de la plateforme CommonVoice, sur laquelle la qualité audio est généralement très bonne. Les résultats sont encourageants : le modèle n'est entraîné que sur 7 langues, mais il atteint tout de même des performances compétitives, avec notamment un PER (Phoneme Error Rate) de 21.0% et un PFER (Phonetic Feature Error Rate) de 5.7% sur des langues vues pendant l'entraînement, et un PER 63.2% sur des langues complètement inconnues. Les résultats sont d'autant plus encourageants qu'ils surpassent ceux du modèle de transcription phonétique considéré comme le meilleur jusqu'ici (Wav2Vec2Phoneme). En effet, Wav2Vec2Phoneme avait obtenu un PER global de 65.8% lors de l'évaluation sur quatre langues inconnues, les mêmes que celles pour lesquelles MultIPA avait obtenu 63.2%.

Plus récemment, (Suchardt et al., 2025) présentent leurs travaux sur l'utilisation de modèles d'ASR pour générer des transcriptions phonétiques. Comme (Taguchi et al., 2023), leur objectif est d'obtenir un système qui puisse faire une transcription phonétique de l'oral qui ne soit pas dépendante de la langue, donc qui puisse prendre en charge toutes les langues, et notamment les langues peu dotées. Leur approche consiste à fine-tuner des modèles basés sur le modèle Whisper (Radford et al., 2023), pour transcrire directement en alphabet phonétique international. Les performances de leur système dépassent celles du modèle MultIPA de (Taguchi et al., 2023) pour les langues connues comme pour les langues inconnues, malgré un entraînement sur un nombre réduit de données. En effet, le meilleur modèle de (Suchardt et al., 2025), LoWhIPA, obtient un PER moyen de 14.18% et un PFER de 4.95% pour des langues vues pendant l'entraînement, là où MultIPA obtient un PER moyen de 29.72% et un PFER de 8.80%. Pour les langues inconnues, MulTIPA est légèrement meilleur : les performances sur les langues inconnues sont à 73.05% (PER) et 23.85% (PFER) pour LoWhIPA, là où MulTIPA obtient 68.05% (PER) et 18.86% (PFER). Mais les performances moyennes globales, en confondant les langues connues et inconnues,

sont meilleures pour LoWhIPA (PER 35.57% et PFER 10.65%) que pour MultIPA (PER 43.66% et PFER 12.12%). Cette approche s'avère donc prometteuse pour la transcription phonétique de l'oral, notamment sur des langues peu dotées, car LoWhIPA a été entraîné sur une petite quantité de données.

2. Collecte des données

2.1. Conditions générales pour la constitution du corpus

Afin d'avoir un corpus utilisable, plusieurs conditions doivent être réunies. Tout d'abord, le corpus doit être constitué d'audios en occitan, idéalement d'un locuteur ayant un accent natif. En effet, l'objectif étant de restituer la phonétique de l'occitan, avoir un accent non-natif et donc des phonèmes non-occitans introduirait du bruit dans les résultats. Ensuite, il est essentiel que chaque audio soit accompagné de sa transcription. Il est probable que le format des données, et notamment des transcriptions, ne soit pas toujours normalisé, d'autant plus lorsqu'on traite une langue peu dotée, pour laquelle les ressources proviennent souvent de plusieurs sources différentes. C'est pourquoi nous acceptons tout type de transcription, qu'elle soit phonétique, phonémique ou orthographique. Si aucune transcription n'accompagne l'audio, il sera impossible de produire une référence sur laquelle se baser pour évaluer les performances du modèle. En revanche, si on dispose d'une transcription de base, quel que soit son format, on peut implémenter une pipeline pour la rendre utilisable, bien que l'hétérogénéité des formats rende l'exploitation des données plus compliquée. Si les données récoltées remplissent ces conditions, nous pouvons les intégrer au corpus.

2.2. Constitution du corpus

2.2.1. CommonVoice

Le premier corpus que nous avons récolté est celui de CommonVoice. CommonVoice, développé par Mozilla Foundation, est un corpus de parole accessible librement. Il se base sur une plateforme participative d'enregistrement de données vocales. Le but de cette plateforme est de récolter des données vocales aussi représentatives de chaque langue que possible, c'est-à-dire incluant tous les accents, les genres, les classes sociales, etc. Chacun peut offrir

ses services en s'enregistrant dans sa langue natale. La participation consiste à s'enregistrer en lisant des phrases ou de courts textes, le but étant d'avoir des données disponibles pour l'entraînement et le test de modèles de reconnaissance de la parole. Le corpus couvre un large panel de langues, et tous les enregistrements sont fournis avec leur transcription orthographique.

Ce corpus constitue une base de données particulièrement intéressante pour la tâche que nous voulons effectuer au cours de ce stage, notamment car le modèle que nous souhaitons tester est entraîné, comme beaucoup de systèmes d'ASR, sur des données venant de CommonVoice. Pour qu'un échantillon vocal soit accepté dans un corpus de CommonVoice, les conditions sont que la voix soit claire et compréhensible, sans bruit de fond et sans qu'une autre personne parle en même temps. Les données de CommonVoice sont donc très propres, ce qui rendra a priori la tâche plus facile au modèle lorsqu'on le testera dessus. Nous avons récupéré le corpus *CommonVoice Scripted Speech 25.0 - Occitan*. Dans le cadre de ce stage, le corpus occitan de CommonVoice est le corpus le plus propre et le plus large dont nous disposons.

Cependant, l'utilisation de ce corpus comporte aussi des limites. Le fait que les phrases soient lues et enregistrées dans des environnements calmes, sans aucun bruit autour, rend les audios moins représentatifs de la réalité. Les locuteurs peuvent par exemple être amenés à parler plus lentement et articuler plus qu'ils ne le feraient naturellement, ce qui rend les données plus "artificielles". Ceci est d'autant plus problématique que beaucoup d'audios en occitan extraits d'autres corpus que CommonVoice ont une qualité beaucoup plus faible ; on ne peut donc pas considérer que les résultats obtenus sur ce corpus seront les mêmes lors du test du modèle sur d'autres corpus.

Concernant le format des données, le corpus de CommonVoice en occitan contient les clips audios, en format mp3, ainsi que des fichiers tsv séparés en train, test et dev. Chaque fichier tsv contient les informations suivantes: les chemins des fichiers, la transcription orthographique de chaque audio, ainsi que des métadonnées telles que la catégorie d'âge et le genre du locuteur pour chaque audio. Les données sont récupérées depuis les fichiers tsv au moyen d'un script python. La durée moyenne des clips audios du corps est d'environ 4.87 secondes par clip, et l'ensemble de test du corpus est composé de 275 clips, soit environ 22 minutes d'enregistrement.

2.2.2. OcOr

Le corpus OcOr (Occitan Oral narratives) est un corpus de contes en occitan collectés par le Conservatoire Occitan des Musiques et Danses Traditionnelles (COMDT),[5] auprès de locuteurs natifs de l'occitan. Il a été récolté dans le cadre du projet OcOr (Occitan Oral), dont le but est de collecter, diffuser et préserver des archives sonores occitanes. Les chercheurs ayant collecté ces données orales les ont ensuite transcrites et numérisées. Les fichiers audios sont téléchargeables en format mp3 et les transcriptions sont accessibles sur Zenodo.[6] Ce corpus semble donc remplir nos conditions pour être utilisable: les audios sont en occitan, par des locuteurs natifs, et des transcriptions y sont associées. L'une des différences majeures avec le corpus de CommonVoice est que les audios du corpus OcOr sont plus naturels, car il s'agit d'enregistrement de productions orales quasi-spontanées. La consigne donnée aux locuteurs n'est pas de lire un conte, mais de le raconter à leur façon, comme ils s'en souviennent. Ce corpus est intéressant pour notre projet car il permet de tester le modèle sur des données moins propres et plus naturelles que le corpus de CommonVoice.

Cependant, plusieurs problèmes se sont présentés avec Ocor. Tout d'abord, le corpus téléchargeable sur Zenodo ne contient que les transcriptions. Pour obtenir les audios, il faut se rendre sur le site du COMDT et les chercher manuellement, mais ils ne sont pas tous accessibles librement. Certains sont des livres audios payants, et sont donc protégés par des droits d'auteur. À l'inverse, tous les audios disponibles sur le site du COMDT n'avaient pas forcément de transcription associée dans le corpus, il nous était donc impossible de les utiliser. Finalement, sur les 27 transcriptions dont nous disposions au départ, nous n'avons pu récupérer que 4 audios correspondants, ce qui correspond à un total de 11 minutes d'enregistrement. De plus, les audios disponibles sur le site du COMDT sont "bruts", c'est-à-dire que l'enregistrement a en général été fait en une seule fois et n'a pas été nettoyé. Ainsi, les audios récupérés contiennent des interruptions, des hésitations ou des bruits "parasites", tels qu'une porte qui claque par exemple. Enfin, les transcriptions contenues dans le corpus n'étaient pas toujours strictement exactes. Les hésitations et les mots répétés par le locuteur, par exemple, ne sont pas toujours renseignés dans la transcription. Une révision des transcriptions, sur laquelle nous reviendrons en partie 2.3.2., a donc été nécessaire afin de pouvoir utiliser le corpus.

[5] http://www.comdt.org/
[6] https://zenodo.org/records/1451753

2.2.3. Chants

Le corpus que nous appellerons ici « Chants » est composé d'extraits de chants traditionnels occitans. Ces extraits ont été récupérés depuis la plateforme YouTube ou depuis des CD de groupes de musique. Deux des groupes dont nous avons pu récupérer des extraits pour l'instant sont des groupes chantant spécifiquement de la musique traditionnelle occitane (Duo Corbefin Marsac[7] et La Man Encantada[8]). Le troisième groupe dont nous avons pu récupérer des audios est le Poème Harmonique.[9] Il s'agit d'un groupe de musique ancienne qui a enregistré un CD contenant des airs traditionnels occitans, que nous avons récupérés. La majorité de ce corpus provient de CD personnels et n'est pas dans le domaine public ; même si certains textes sont disponibles dans le domaine public (notamment les paroles de La Man Encantada), les interprétations sont sous droits exclusifs des artistes. Il ne nous est donc pas possible de rendre disponible le corpus en cours de constitution.

Une fois les pistes audios extraites du CD, nous avons dû passer à une première étape d'extraction et de nettoyage des données pertinentes. En effet, les chants sont souvent accompagnés de parties uniquement instrumentales, qui sont du bruit pour un modèle de transcription.

Nous avons donc procédé à un découpage des pistes audios avec Audacity. Pour optimiser les chances de réussite du modèle et faciliter la vérification des prédictions, nous avons préféré découper les audios en plusieurs pistes courtes, souvent par blocs de deux ou trois phrases. Les parties exclusivement instrumentales ont été supprimées pour ne garder que le texte, mais les pistes audios découpées contenaient toujours un fond instrumental accompagnant la voix. Nous avons donc isolé la voix afin d'avoir des audios sans aucun fond instrumental, d'une part pour avoir plus de données, et d'autre part pour pouvoir comparer les performances du modèle en fonction de si la voix est seule ou accompagnée d'un fond instrumental. L'isolation de la voix a été faite avec l'outil en ligne vocalremover.[10] Les données audios de ce corpus sont donc composées de pistes avec voix et accompagnement instrumental, et des mêmes pistes « a capella », c'est-à-dire la voix seule sans accompagnement.

[7] https://sites.google.com/site/duocorbefinmarsac/
[8] https://www.manencantada.com/
[9] https://lepoemeharmonique.fr/
[10] vocalremover.org

Comme pour les autres corpus, nous avons fait face à quelques difficultés lors de la constitution de ce corpus. L'un des problèmes majeurs avec ce corpus est la polyphonie (le fait d'avoir plusieurs voix en même temps). De nombreuses pistes se sont avérées inutilisables car elles comportaient plusieurs chanteurs, et notamment des paroles différentes chantées en même temps (canon ou deuxième voix par exemple). Il y a donc une perte de données lors de la constitution de ce corpus. Nous avions d'ailleurs comme but d'utiliser des pistes audio du groupe La Mal Coiffée,[11] un autre groupe chantant des airs traditionnels occitans, mais le groupe chante systématiquement en polyphonie, la plupart du temps avec deux voix à la fois qui chantent des paroles différentes. Il nous semblait impossible pour un modèle de faire de la transcription phonétique lorsque plusieurs choses différentes sont dites en même temps, nous avons donc laissé ce corpus de côté. Une autre difficulté que nous avons rencontrée, et qui ralentit la constitution de ce corpus, est le fait que les transcriptions (les paroles des chansons) sont écrites dans un livret papier et ne sont pas numérisées. Pour avoir un corpus utilisable, il faut donc numériser les transcriptions manuellement, ou bien il faudrait avoir recours à des techniques d'OCR. En outre, il est important de noter qu'à ce stade du stage, le corpus est toujours en cours de constitution, et n'a donc pas encore été entièrement exploité.

2.2.4. Occiton2

Parmi les corpus audios disponibles en ligne figurait aussi le corpus Occiton2, créé par les chercheurs Jean-Louis Fossat et Abderrahim Meqqori dans le cadre d'un projet portant sur l'occitan et son traitement informatique. L'objectif du projet Occiton2 est de faciliter la fouille de données et le traitement du langage pour l'occitan. Le corpus est composé de nombreux enregistrements, accompagnés d'annotations diverses : une transcription orthographique, une transcription phonétique, et parfois des indications sur les traits articulatoires. Ce corpus est particulièrement intéressant dans le cadre du stage car les informations sont déjà structurées et les transcriptions phonétiques sont fournies.

Cependant, à ce jour, nous n'avons pas encore pu utiliser ce corpus car les transcriptions phonétiques étaient dans une convention que nous ne connaissions pas, et pas en API. De plus, les transcriptions orthographiques fournies avec les audios sont en général

[11] https://www.lamalcoiffee.com/

approximatives : tous les mots ne sont pas transcrits, parfois seuls les mots-clés le sont, et les transcriptions en occitan sont parfois accompagnées de commentaires et d'explications. Par exemple, les mots soulignés dans la transcription suivante ne font pas partie de l'audio :

"***lo ròc, la pèira , lo sistre e lo silhon§, DG&//****çò primièr voldriá saber per çò qu'es del potz/euh.../lo terren/a Carmaus/lo....-cossí dirai?-/i a de .../ es de ròc o es de carbon?//es de bona qualitat/rapòrt a.../-vesetz çò que vòli dire?// [MOT NON TRANSCRIT] qu'una qualitat de carbon i a* ***a Carmaus?//$, A$//****[MOT NON TRANSCRIT] i a de bona qualitat a Carmaus//$, B$//de carbon gras//* ***$, DG&****//carbon gras//* ***&[écho/validation]****, A$//i a.../i a de totas cochas// n'i a de cochas pauras/me(s) n'i a de me(s) grassas/eh!//n'i a de polidas/perque/dins las espessors de d'aquò's/i a [MOT NON TRANSCRIT] d'espessors de uèit o nou mèstres/d'espessor//alara/i a doas cochas de polit/e apuèi i a una cocha pus magra/e entremieg las cochas/i a .../i a un silhon/un silhon/un d'aquò's//$, B$//i a de pèiras//$, A$//apelam aquò/.../ una pèira//-de sistre/-s'apèla//$*".

Certains commentaires comme "*écho/validation*" sont présents à de nombreuses reprises dans les transcriptions mais ne sont pas prononcés dans les audios, alors que d'autres commentaires comme par exemple "*Annonce par D. Gonzalez, bande d'enregistrement G81 [...]"* sont prononcés dans l'audio. Cela nous empêche de retirer systématiquement tous les commentaires des transcriptions sans écouter les audios. Conjointement avec les encadrants, nous avons donc décidé de ne pas utiliser immédiatement le corpus, et de contacter Jean-Louis Fossat dans le but d'avoir des explications sur les conventions utilisées pour la transcription phonétique, et ainsi d'obtenir des transcriptions plus propres. Nous sommes actuellement en attente de la réponse de M. Fossat, et n'avons donc pas encore utilisé le corpus. La Figure 12, en annexe, montre un exemple de l'interface sur laquelle est disponible le corpus, ainsi que les transcriptions.

2.3. Les données de référence

2.3.1. Phonétisation avec Lo Congrès

Les transcriptions dont nous disposions pour nos trois corpus étaient uniquement des transcriptions orthographiques. Or, notre projet portant sur la transcription phonétique, nous avons besoin de transcriptions phonétiques associées à nos audios, afin d'avoir une référence

sur laquelle nous baser. L'un des phonétiseurs les plus intéressants que nous ayons trouvés était le phonétiseur de Lo Congrès.[12]

Lo Congrès est un organisme qui rassemble des institutions et fédérations occitanes ayant pour but de réguler et normaliser la langue occitane. L'organisme a notamment pour objectif de développer des outils numériques en occitan afin de pallier au problème de marginalisation dont souffre la langue. C'est pourquoi il nous a paru fiable d'utiliser ce phonétiseur pour constituer notre référence, plutôt qu'un phonétiseur multilingue qui risquerait d'être moins précis. Pour chaque audio, la transcription phonétique est obtenue automatiquement en passant la transcription orthographique au phonétiseur, au moyen d'un script de requête à l'API de Lo Congrès.[13] Lo Congrès propose une transcription dans les six variantes d'occitan. Cela nous permet d'obtenir une transcription de référence sur laquelle nous baser par la suite.

2.3.2. Difficultés et solutions adoptées

Nous avons tout de même rencontré plusieurs difficultés lors de la collecte des données de référence. Les transcriptions de Lo Congrès sont une très bonne base et seront essentielles à l'évaluation de notre modèle, néanmoins il est important de noter qu'elles ne peuvent pas encore être considérées comme un gold standard car elles sont basées sur l'écrit. Elles représentent une prononciation "idéale" et ne prennent pas en compte les variations de la langue propres à l'oral, et propres à chaque audio.

Afin de pallier au maximum ce problème, nous avons eu recours à un nettoyage manuel sur les petits corpus (Ocor et Chants). Le nettoyage manuel consiste à repasser sur la transcription de Lo Congrès en écoutant l'audio, et à la corriger manuellement pour s'approcher au maximum d'un gold standard. Toutefois, cette solution est difficilement applicable à un corpus plus grand, comme celui de CommonVoice, car elle nécessite de se pencher sur chaque audio individuellement et n'est donc pas réalisable dans le temps dont nous disposons. Nous avons donc gardé le silver standard pour le corpus CommonVoice, élément qu'il sera essentiel de prendre en compte lors de l'évaluation du modèle.

De plus, l'occitan comporte six variantes principales. Or, ceci engendre plusieurs difficultés. Premièrement, nous ne savons pas quelle variante est parlée dans les audios dont nous disposons, à l'exception des audios du corpus de chants (majoritairement en gascon). Il

[12] https://locongres.org/fr/lo-congres/lettre-de-liaison/un-fonetizaire-occitan-en-linha
[13] https://api.locongres.org/?lang=fr

est donc impossible de ne choisir qu'une seule variante lors de l'étape de transcription avec Lo Congrès sans risquer une perte dans la référence. Nous avons donc décidé de récupérer, pour chaque audio, les six transcriptions de Lo Congrès. Ainsi, les données de référence se composent, pour chaque audio, d'une liste de six transcriptions. Nous reviendrons ultérieurement sur la façon dont ces listes de transcriptions sont gérées pour l'évaluation.

3. Mise en place du pipeline de transcription automatique

3.1. Outils et bibliothèques utilisés

Au cours du stage, j'ai progressivement mis en place une pipeline de traitement des données et de test et évaluation du modèle. L'ensemble du code a été écrit en Python dans Visual Studio Code, et est disponible sur GitHub.[14] Pour ce qui est des bibliothèques Python, nous avons utilisé des librairies fréquemment utilisées dans les projets de data science et de TAL :

- Scikit-learn
- Numpy
- Pandas
- NLTK
- PyTorch
- Transformers
- PanPhon (librairie d'analyse phonétique sur laquelle nous reviendrons ultérieurement)

Nous avons également utilisé des outils extérieurs à Python:

- Audacity pour le découpage des audios
- Vocalremover pour l'isolation des voix

3.2. Le modèle Wav2Vec2Phoneme

[14] https://github.com/Manon09825/Traitement-automatique-de-l-oral---occitan/tree/main

Le modèle testé et évalué au cours de ce stage est Wav2Vec2Phoneme (Xu et al., 2021). Il s'agit d'un modèle de transcription de l'oral vers l'alphabet phonétique international (API). Il est basé sur l'architecture Wav2Vec 2.0, conçue pour la reconnaissance automatique de l'oral (ASR). (Baevski et al., 2020). La différence avec wav2vec 2.0 est que wav2vec2phoneme transcrit directement en alphabet phonétique. L'utilisation de ce modèle est pertinente dans le cadre de ce stage pour plusieurs raisons : l'outil transcrit directement en API, ce qui évite de devoir passer par plusieurs modèles, en transformant la sortie d'un modèle d'ASR plus classique par exemple. De plus, il a été testé sur des langues peu dotées et a obtenu des résultats encourageants : sur le zoulou, langue sur laquelle il a été entraîné, il obtient un taux d'erreur (PER) de seulement 34.6%, comparé à 35.2% pour le modèle de (Gao et al., 2021), qui proposent aussi une méthode de reconnaissance phonétique en zero-shot. Pour le cantonais et le lao, que le modèle n'a jamais vus en entraînement, le taux d'erreur est de 63.6% et 63.7% respectivement, contre 73.1% et 69.3% pour le modèle de Gao et al.

3.2.1. Entraînement

Le modèle a été entraîné sur des corpus oraux venant de CommonVoice et Babel, dans 45 langues, plus ou moins bien dotées. Il a notamment été entraîné sur le corpus catalan de CommonVoice, ce qui est particulièrement intéressant dans le cadre de ce stage, puisque le catalan partage des origines avec l'occitan, et en est donc très proche phonétiquement. Le modèle n'ayant pas été entraîné ni testé sur l'occitan, on ne s'attend pas à avoir d'excellents résultats, cependant le fait qu'il ait été entraîné sur des langues proches comme le catalan, l'espagnol et le français sera sûrement une aide pour le transfert vers l'occitan. Les phonèmes de l'occitan ne seront pas complètement nouveaux pour le modèle.
Il est intéressant de noter que les corpus d'entraînement sont relativement "propres". En effet, CommonVoice n'accepte des fichiers audios dans les corpus qu'à condition qu'ils soient de bonne qualité, sans bruits de fond. Le corpus Babel est également composé d'audios très propres, enregistrés en studio. On s'attend donc à ce que les performances baissent si jamais la qualité des audios n'est pas optimale.

3.2.2. Pipeline de test du modèle

Pour tester le modèle, nous avons implémenté la pipeline suivante:

- Chargement des données (audios et transcriptions graphiques)

- Conversion des transcriptions graphiques en transcriptions phonétique
- Passage au modèle et récupération des prédictions
- Nettoyage des transcriptions
- Alignement des prédictions avec la référence
- Expériences et évaluation

3.3. Stratégies d'alignement avec la référence

3.3.1. Distance de Levenshtein

Afin de pouvoir calculer le taux d'erreur du modèle par rapport à la référence, il s'est avéré nécessaire de procéder à un alignement des deux chaînes de phonèmes (la référence de Lo Congrès et la prédiction du modèle). Nous avons procédé à une première stratégie d'alignement, en utilisant la fonction edit_distance_align() de la bibliothèque NLTK. Cette fonction est basée sur la distance de Levenshtein, qui mesure la différence entre deux chaînes de caractères, c'est-à-dire le nombre minimal d'opérations (substitutions, insertions et suppressions) à effectuer pour passer d'une chaîne à l'autre. La fonction cherche et applique l'alignement pour lequel le coût total est le plus faible, c'est-à-dire avec le moins de substitutions, d'insertions et de suppressions possible.

Cependant, nous avons vite constaté que cette méthode d'alignement présentait des limites. En effet, l'alignement avec edit_distance_align() est plus mathématique que phonétique. Notamment, la proximité entre les phonèmes n'est pas prise en compte dans l'alignement ; chaque substitution a le même coût, que ce soit entre deux phonèmes proches comme "a" et "ɔ" ou "a" et "p". Prenons par exemple la phrase "Que sò ara vòsta disposicion, didec.", transcription orthographique de l'un des audios. La transcription de référence (celle de Lo Congrès) est la suivante: "kesɔarəbɔstɔdispuzisjudidek", et le modèle a prédit: "kesoɾavɔstɐðispozisjondiɾek".
L'alignement produit par edit_distance_align() est le suivant:

true	k	e	s	ɔ	a	r	ɔ	b	t	ɔ	d	i	s	p	u	z	i	s	j	u	d	i	d	e	k
pred	k	e	s	o	a	v	ɔ	s	t	ɐ	ð	i	s	p	o	z	i	s	j	o	d	i	ɾ	e	k

TABLE 1 - *Alignement entre la prédiction du modèle et la transcription de référence avec edit_distance_align() pour la phrase "Que sò ara vòsta disposicion, didec."*

La Table 1 montre que certains phonèmes ont disparu au profit d'un alignement moins coûteux. On se retrouve donc avec une transcription "true" qui ne reflète plus vraiment l'audio, et avec un alignement parfois faux. Par exemple, si l'alignement avait été fait manuellement, les phonèmes 'k e s ɔ a r ɔ b ɔ' (Lo Congrès) auraient été alignés avec 'k e s o (-) ɾ a v ɔ' (modèle). Pour éviter la substitution, la fonction a aligné le 'a' transcrit par Lo Congrès avec le 'a' prédit par le modèle. Cependant, les deux 'a' ne représentaient pas le même phonème de l'audio, et le résultat est donc faussé, puisqu'on considère ici qu'il n'y a pas de substitution alors qu'en réalité, le modèle n'a rien prédit quand Lo Congrès a transcrit 'a', et Lo Congrès a transcrit 'ɔ' là où le modèle a prédit 'a'. L'alignement indique une correspondance exacte entre la référence et la prédiction du modèle, là où il y a en réalité une suppression puis une substitution. Cela risquerait de fausser les résultats lors de l'évaluation des performances du modèle.

3.3.2. Analyse phonétique avec PanPhon

Afin de pallier aux limites de l'alignement avec NLTK, nous avons cherché des bibliothèques Python plus adaptées à la tâche d'alignement de phonèmes. Nous avons donc cherché d'autres méthodes d'alignement, et avons découvert la librairie PanPhon (Mortensen et al., 2016). PanPhon est une bibliothèque qui permet de représenter les phonèmes de l'API par leurs caractéristiques articulatoires. Chaque phonème est associé à 21 traits articulatoires, tels que le voisement ou le lieu d'articulation par exemple. PanPhon convertit chaque phonème en un vecteur de traits articulatoires. PanPhon permet donc de tenir compte de la proximité phonétique entre deux phonèmes, ce qui est particulièrement utile lorsqu'il s'agit d'aligner deux séquences de phonèmes.

Pour l'alignement, PanPhon se base donc sur les traits articulatoires et la proximité phonétique des phonèmes entre eux. Au lieu d'être alignés selon le coût total, les phonèmes sont alignés selon leur proximité. Reprenons l'exemple de la phrase "Que sò ara vòsta disposicion, didec.".

L'alignement produit par PanPhon est le suivant :

true	k	e	s	ɔ	a	r	ɔ	b	ɔ	s	t	ɔ	d	i	s	p	u	z	i	s	j	u	-	d	i	d	e	k
pred	k	e	s	o	-	ɾ	a	v	ɔ	s	t	ɐ	ð	i	s	p	o	z	i	s	j	o	n	d	i	ɾ	e	k

TABLE 2 - *Tableau de l'alignement entre la prédiction du modèle et la transcription de référence avec PanPhon pour la phrase "Que sò ara vòsta disposicion, didec."*

Comme l'illustre la Table 2, l'une des différences qu'apporte PanPhon par rapport à l'alignement de NLTK est l'introduction de tirets "-" pour signifier une suppression ou une insertion. Dans cet alignement, une suppression dans la prédiction du modèle se traduit par un tiret dans la prédiction, alors aligné avec le phonème de Lo Congrès qui n'a pas été prédit. De même, une insertion se traduit par l'ajout d'un tiret dans la référence, aligné avec le phonème inséré par le modèle. Pour aligner les phonèmes, on établit d'abord un coût de substitution pour chaque paire de phonèmes grâce à la fonction weighted_feature_edit_distance() de PanPhon, qui calcule la distance entre deux phonèmes. Plus les deux phonèmes sont proches en termes de traits articulatoires, plus le coût de substitution sera élevé, et inversement, plus deux phonèmes sont éloignés, moins le coût de substitution sera élevé. Lors du test et de la comparaison des deux techniques d'alignement sur plusieurs chaînes de phonèmes, la qualité de l'alignement avec PanPhon s'est avérée systématiquement supérieure à celle de l'alignement avec NLTK. Nous avons donc choisi PanPhon comme stratégie d'alignement définitive.

4. Expériences et évaluation

4.1. Préparation des données pour l'évaluation

4.1.1. Nettoyage

Afin que l'évaluation soit aussi représentative que possible des performances du modèle, une étape de préparation des données est nécessaire. La préparation inclut tout d'abord un nettoyage des transcriptions. Le phonétiseur de Lo Congrès garde la ponctuation dans ses transcriptions, que la fonction de nettoyage permet de retirer. Cette dernière contient également quelques contraintes pour le prédicteur : les phonèmes qui ont été prédits par le

modèle mais qui ne sont jamais prédits par Lo Congrès (donc a priori les phonèmes qui ne font pas partie de la phonétique de l'occitan) sont remplacés par le phonème de l'occitan le plus proche. Par exemple, le phonème /β/ est parfois prédit par le modèle alors qu'il n'est jamais utilisé par Lo Congrès. La fonction de nettoyage fait donc en sorte qu'il soit toujours remplacé par /b/, qui est un phonème de l'occitan souvent transcrit par Lo Congrès. Un autre exemple est le phonème /ʌ/, parfois prédit par le modèle, mais à la place duquel Lo Congrès transcrit presque systématiquement le phonème /ə/. Le fait que Lo Congrès n'utilise jamais ces phonèmes mène à penser qu'ils ne font pas partie de la phonétique occitane, d'où l'intérêt de contraindre le prédicteur afin qu'il les remplace systématiquement par des phonèmes qui appartiennent à la phonétique occitane. De même, la diphtongue /aʊ/ était systématiquement transcrite /aw/ par Lo Congrès, ce qui était compté comme une erreur lors de l'évaluation, bien que ces deux transcriptions symbolisent le même son. Faire en sorte que la prédiction coïncide avec la référence dans ce cas permet d'éviter d'avoir des erreurs comptées inutilement.

4.1.2. Récupération des références

Comme évoqué en 3.2, chaque audio a comme référence une liste de six transcriptions, une dans chaque variante. Une fois les données nettoyées, il faut donc récupérer une seule transcription de référence pour chaque prédiction. Pour les corpus de CommonVoice et Ocor, nous ne connaissions pas la variante parlée par les locuteurs, nous ne savions donc pas laquelle des six transcriptions de Lo Congrès utiliser comme référence. Afin de récupérer la meilleure référence pour chaque prédiction, nous avons procédé à plusieurs expériences. Tout d'abord, nous avons mis en place une fonction qui, pour chaque prédiction, parcourt la liste des six transcriptions de référence et calcule la distance de Levenshtein entre la prédiction et chacune des six transcriptions. La transcription pour laquelle la distance est la plus petite est alors gardée comme référence pour la prédiction. Nous obtenons donc une liste "personnalisée", avec la transcription la plus proche pour chaque prédiction.

Cependant, cette méthode n'est pas parfaitement fiable car le modèle peut faire des erreurs qui rendent sa prédiction plus proche de l'une des six transcriptions de Lo Congrès, alors qu'une autre variante est plus proche de l'audio. Prenons l'exemple d'un audio dans lequel le mot "encantada" serait prononcé par un locuteur gascon, et pour lequel le modèle aurait prédit /e n k a n t a d a/. La transcription correcte serait alors /e n k a n t a d ɔ/, car en gascon, les "a" en fin de mots se prononcent /ɔ/. Mais prendre la variante la plus proche

reviendrait à choisir la variante vivaro-alpine, dans laquelle les “a” en fin de mot sont prononcés /a/. Cela mènerait donc à la conclusion erronée que le modèle n’a fait aucune erreur et que la variante parlée dans l’audio est la variante vivaro-alpine.

Nous avons donc fait un autre test : celui de prendre une seule variante à la fois comme référence pour toutes les prédictions, et de comparer les résultats. Les résultats étant systématiquement meilleurs lorsque la transcription en gascon était prise comme référence, nous avons choisi cette variante comme référence pour toutes les prédictions.
Pour le dernier corpus, nous savions que les chants étaient en gascon, le choix de la transcription en gascon comme transcription de référence était donc évident.

4.1.3. Application de l’alignement

Une fois que les transcriptions sont nettoyées et que la variante de référence a été choisie, il reste une dernière étape avant de pouvoir procéder à l’évaluation: l’alignement, qui permet de voir exactement le phonème qui a été prédit par rapport à celui qui aurait dû l’être. L’étape d’alignement se fait donc avec PanPhon, comme expliqué en 3.4. Le coût de substitution est ajusté en fonction de chaque paire de phonèmes.

4.2. Métriques d’évaluation

4.2.1. Phoneme Error Rate (PER)

La métrique principale que nous avons utilisée pour évaluer les performances du modèle est le Phoneme Error Rate, ou PER. Nous avons choisi cette métrique car c’est une adaptation du WER (Word Error Rate), une métrique standard pour l’ASR. Le PER est le pourcentage de phonèmes mal prédits par rapport au nombre total de phonèmes. Une fois les chaînes true et pred alignées, le PER est calculé grâce à la fonction edit_distance() de NLTK. Cette fonction calcule la distance de Levenshtein entre deux chaînes de caractères, c’est-à-dire le nombre d’opérations (insertions, substitutions, suppressions) qui doivent être réalisées pour passer d’une chaîne à l’autre. Le PER est calculé pour chaque audio (entre la transcription de Lo Congrès et la prédiction du modèle), puis on fait la moyenne de tous les PER pour avoir un PER global par corpus.

4.2.2. Phonological Feature Error Rate (PFER)

Afin d'évaluer plus précisément les performances du modèle, nous avons aussi calculé le PFER (Phonological Feature Error Rate). Le PFER mesure le taux d'erreur sur les phonèmes prédits par rapport aux phonèmes de référence en termes de similarité phonétique. La différence avec le PER est que toutes les substitutions ne sont pas considérées de la même façon. Par exemple, une erreur entre deux phonèmes proches comme /p/ et /b/ est considérée comme beaucoup moins importante qu'une erreur entre des phonèmes comme /p/ et /a/, et est donc moins pénalisée. Ainsi, le PFER permet de refléter à quel point les phonèmes prédits sont phonologiquement proches des phonèmes de référence. Pour calculer le PFER, on utilise la fonction weighted_feature_edit_distance() de PanPhon. Cette fonction calcule la distance entre deux séquences de phonèmes en ajustant le coût d'erreur en fonction des traits articulatoires des phonèmes.

4.3. Expériences et résultats

4.3.1. Évaluation des prédictions

Nous avons effectué plusieurs expériences afin d'évaluer le modèle. Tout d'abord, un premier calcul du PER a été effectué dans le but de déterminer la variante probable des audios du corpus CommonVoice. Nous avons commencé par calculer le PER et le PFER en prenant la variante la plus proche pour chaque audio. Comme évoqué en 2.3, nous avons d'abord établi une liste y_test contenant la transcription dans la variante la plus proche de la prédiction pour chaque audio, puis nous avons calculé le PER avec cette liste comme référence. Nous avons ensuite calculé les scores PER et PFER du modèle pour chaque variante, c'est-à-dire en prenant toutes les variantes comme référence, une par une.

Nous avons obtenu les résultats suivants :

	PER avec alignement NLTK (%)	PFER (%)
Variante la plus proche	33.35	4.77
Languedocien	35.00	4.97
Vivaro-alpin	43.8	6.75
Auvergnat	43.00	6.04
Limousin	42.37	5.93
Provençal	43.9	6.63
Gascon	34.35	4.86

TABLE 3 - *Résultats de Wav2Vec2Phoneme sur le corpus CommonVoice occitan avec alignement NLTK et sans contraintes du prédicteur*

Nous avons obtenu ces résultats avec la première méthode d'alignement que nous avons utilisée, à savoir la fonction edit_distance_align() de NLTK. On constate que lorsqu'on prend comme référence les transcriptions en gascon de Lo Congrès, les résultats sont meilleurs que lorsqu'on prend une autre variante comme référence. On remarque également que les résultats avec le gascon sont très proches des résultats avec la variante la plus proche pour chaque audio. De plus, une comparaison manuelle de quelques transcriptions avec leur audio a montré que la prononciation correspondait le plus souvent à la transcription en gascon. En prenant en compte ces résultats et le fait que le gascon est l'une des variantes d'occitan pour lesquelles le plus de données sont disponibles (Morcillo et al., 2024), nous avons conclu que les audios du corpus CommonVoice étaient tous, ou du moins la majorité, en gascon, et nous avons donc décidé d'utiliser systématiquement la transcription en gascon comme référence pour les audios de CommonVoice. Les premiers résultats sont particulièrement encourageants : bien que l'occitan ne fasse pas partie des langues d'entraînement du modèle, les performances se rapprochent fortement de celles observées par Xu et al (2021) sur les langues connues, et surpassent largement celles de MultIPA sur les langues inconnues (63.2%).

Après avoir évalué une première fois les performances du modèle sur le corpus de CommonVoice, nous avons collecté plus de données, et avons pu tester le modèle sur un plus grand corpus. Nous avons également changé l'alignement de NLTK pour l'alignement avec PanPhon, beaucoup plus précis. Nous avons séparé les corpus Chants et OcOr en plusieurs sous-corpus pour présenter les résultats car les audios n'ont pas tous été enregistrés dans les mêmes conditions et n'ont pas tous la même qualité au sein d'un corpus. Les sous-corpus de "Chants" portant la mention "vocal" correspondent aux audios pour lesquels le fond instrumental a été enlevé. Nous avons également ajouté les contraintes du prédicteur dans la fonction de nettoyage. La transcription de référence a été nettoyée manuellement pour les corpus OcOr et Chants. En plus du PER général, nous avons calculé le PER uniquement sur les substitutions et les phonèmes corrects, c'est-à-dire sans compter les suppressions et les insertions, afin de voir si les insertions et les suppressions constituaient une grande partie des erreurs. Si le PER sans insertions ou suppressions est relativement similaire au PER avec insertions et suppressions, cela peut signifier que le modèle n'hallucine que très peu, et qu'il perçoit et transcrit la majorité des phonèmes présents dans les audios. À l'inverse, si on trouve une différence importante entre le PER sans insertions et suppressions et le PER général, cela peut signifier que le modèle est sujet à des hallucinations ou qu'il y a beaucoup de phonèmes qu'il ne perçoit pas.

CORPUS	SOUS-CORPUS	PER Aligné (%)	PER SANS INS/DEL (%)	PFER (%)
CHANTS	Corpus complet	33.21	20.88	3.46
	Corbefin-Marsac	56.31	40.00	6.81
	Man Encantada	46.25	31.86	5.69
	Man Encantada - vocal	35.66	23.79	4.62
	Poème Harmonique	29.56	17.82	2.79
	Poème harmonique - vocal	**26.93**	**15.90**	**2.24**
COMMONVOICE	Corpus complet	27.74	20.86	4.86
OCOR	Corpus complet	43.20	30.48	3.97
	Els nau lops	47.23	33.52	4.31
	La taupa e lo grapaud	32.60	23.06	2.88

TABLE 4 - *Résultats de Wav2Vec2Phoneme sur les trois corpus avec l'alignement PanPhon et des contraintes pour le prédicteur*

Comme l'illustre la Table 4, les résultats sont bien meilleurs avec l'ajout de quelques contraintes au prédicteur et l'alignement de PanPhon : pour le corpus CommonVoice, pour lequel la transcription de référence n'a pas été nettoyée, on passe d'un PER de 34.35% à 27.74%, soit une amélioration de 6.61 points. Il est important de rappeler que les transcriptions de référence de Lo Congrès ne sont pas encore un gold standard, et que cela peut donc parfois pénaliser inutilement le modèle. Les résultats ne sont donc pas parfaitement comparables avec ceux de l'état de l'art, cependant ils sont pour l'heure satisfaisants, compte tenu du fait que le modèle n'a jamais été confronté à l'occitan et que, si la transcription de Lo Congrès n'est pas un gold standard parfait, elle constitue tout de même une base assez fiable qu'il est pertinent d'utiliser pour évaluer le modèle. Notons également que les performances sur les chants sont les plus encourageantes, en particulier lorsque le fond instrumental est retiré. La comparaison des résultats du corpus de chants avec et sans fond instrumental montre que la présence d'un fond sonore, même s'il est léger et n'est pas constitué de phonèmes, perturbe le modèle et l'empêche d'atteindre des performances maximales. En

revanche, le fait que les phonèmes soient prononcés en suivant une mélodie et un rythme différents d'une prosodie et un rythme naturels ne semble pas gêner le modèle pour la prédiction, puisque ses résultats sont similaires voire meilleurs que les résultats obtenus pour le corpus de CommonVoice. L'utilisation de chants pour enrichir les corpus oraux constitue donc une piste intéressante. Afin de mieux comprendre les résultats, nous avons regardé les matrices de confusion pour voir quels phonèmes étaient le plus confondus. Pour que les matrices soient lisibles, nous avons fait en sorte qu'elles n'affichent pas les phonèmes qui n'apparaissent que très rarement.

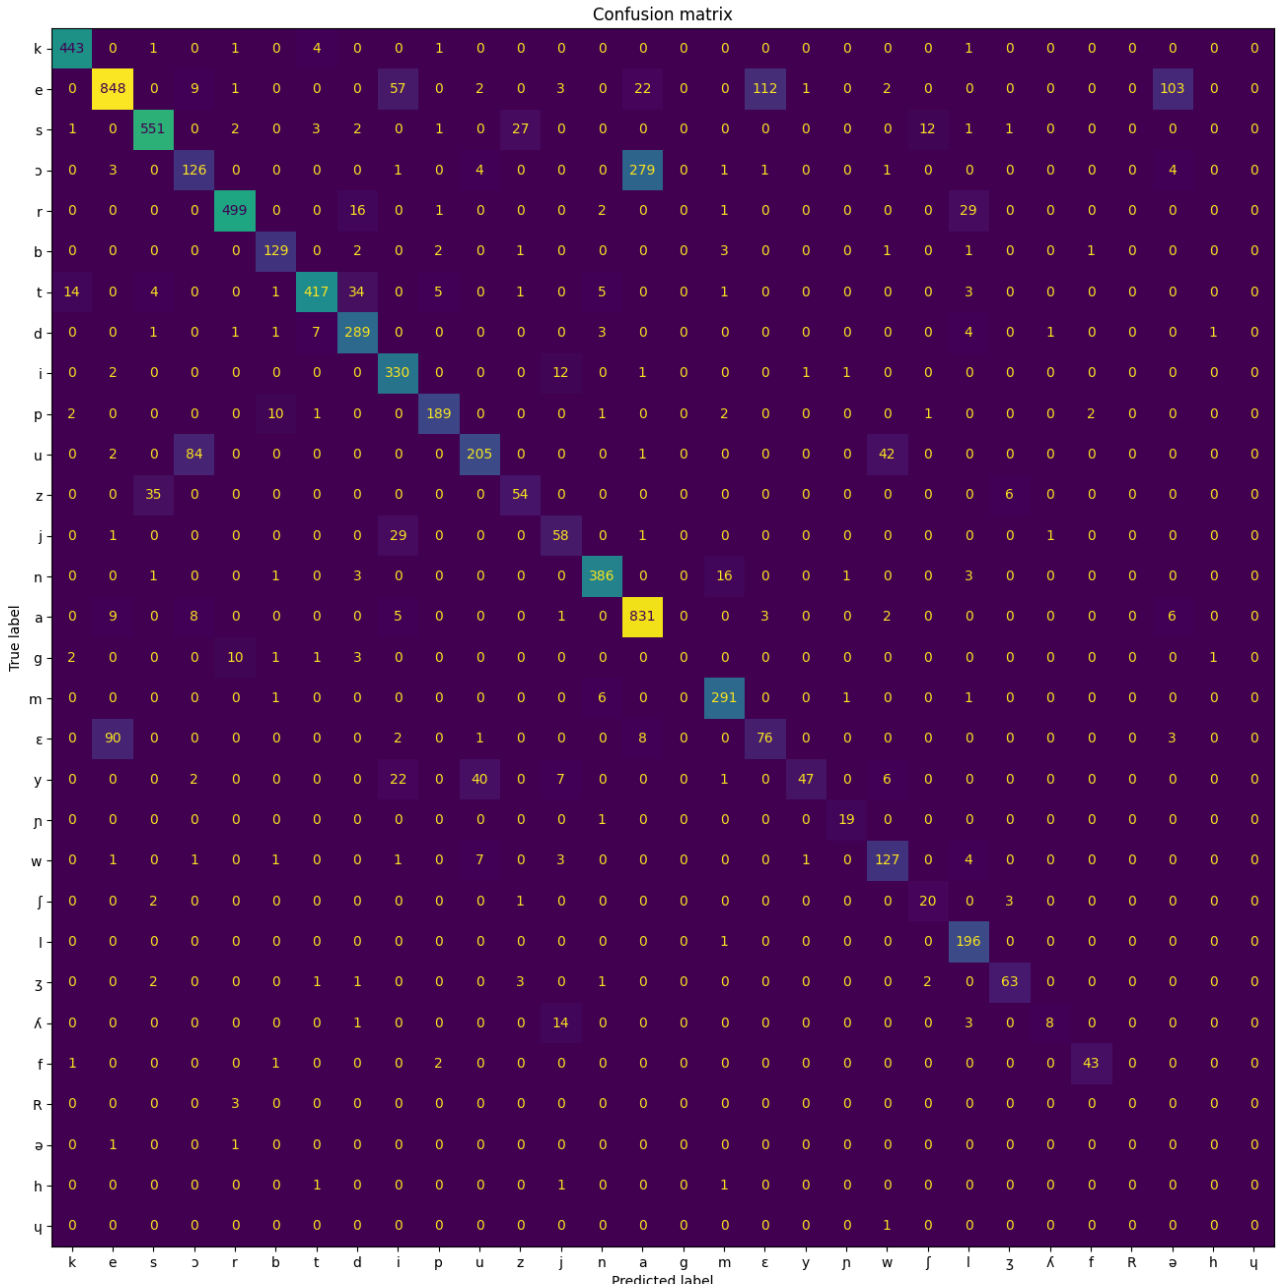


FIGURE 2 - *Matrice de confusion de Wav2Vec2Phoneme sur le corpus de CommonVoice. Les phonèmes sont triés par ordre d'apparition dans la transcription de référence.*

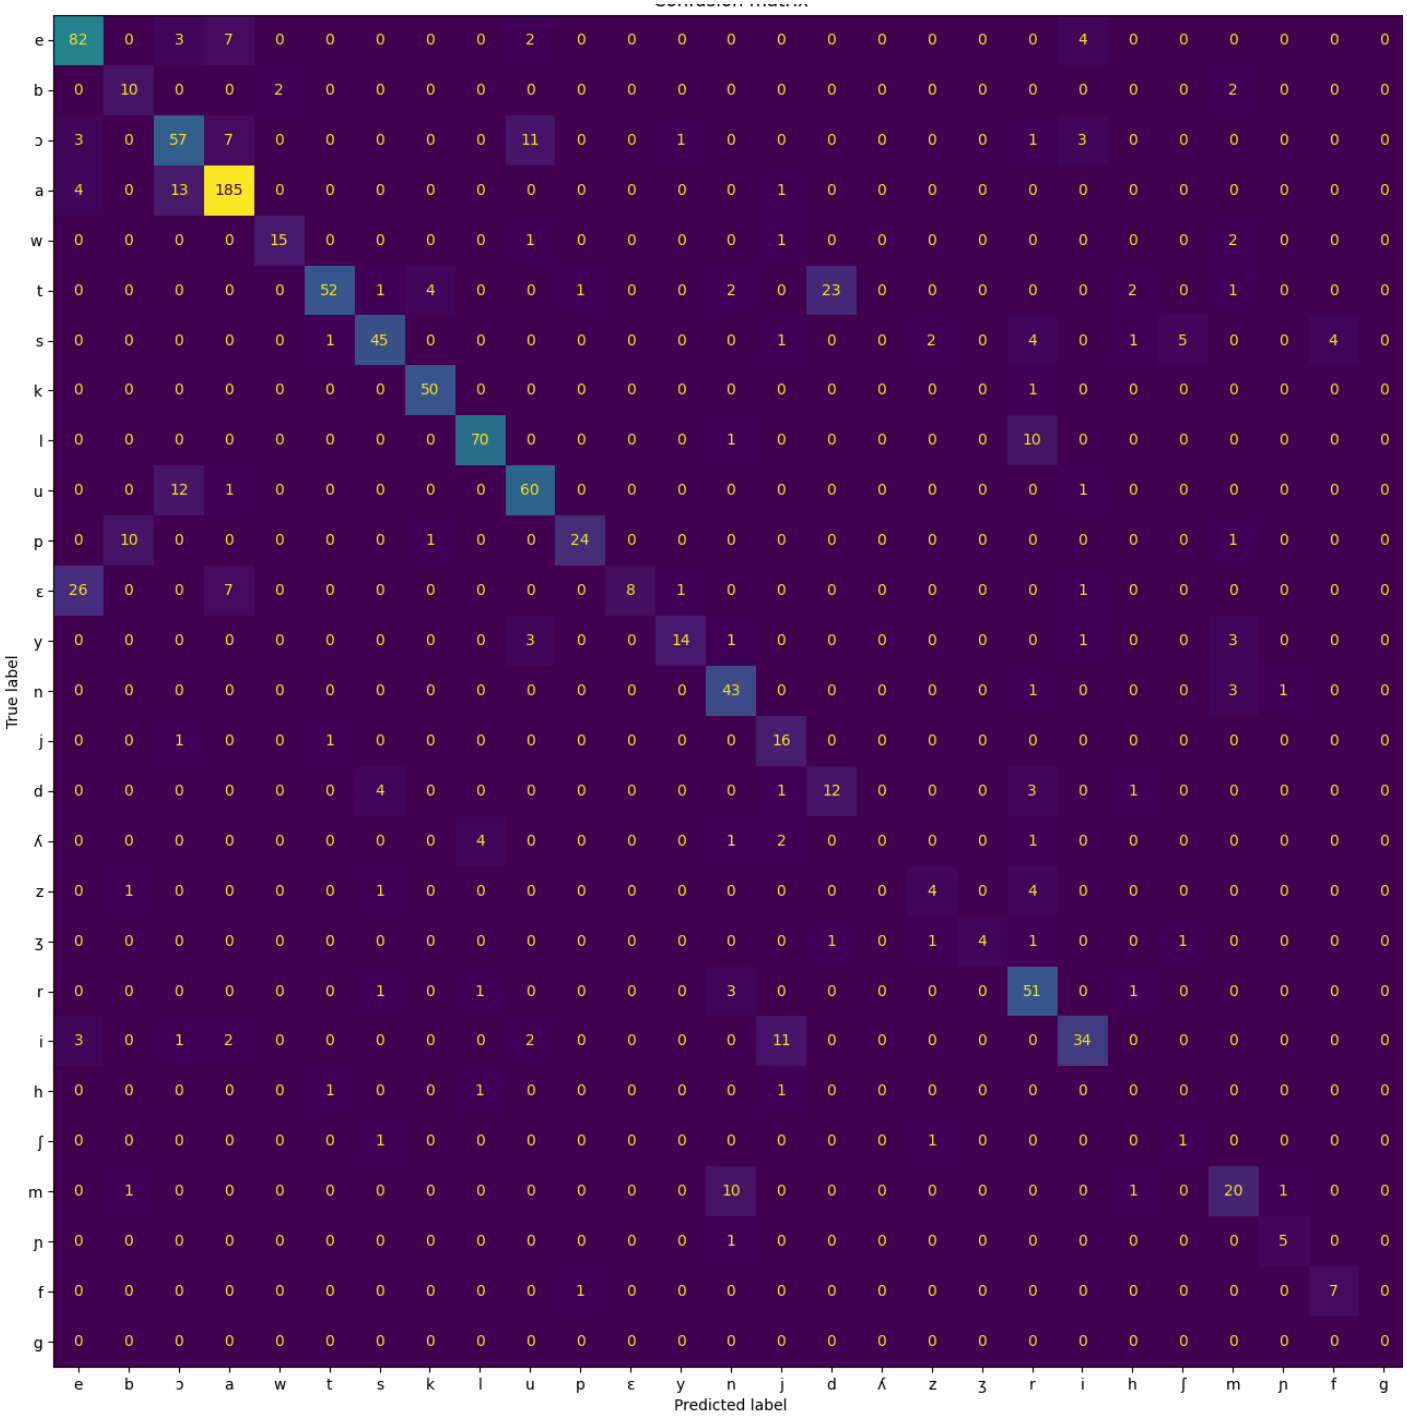


FIGURE 3 - *Matrice de confusion de Wav2Vec2Phoneme sur le corpus OcOr. Les phonèmes sont triés par ordre d'apparition dans la transcription de référence.*

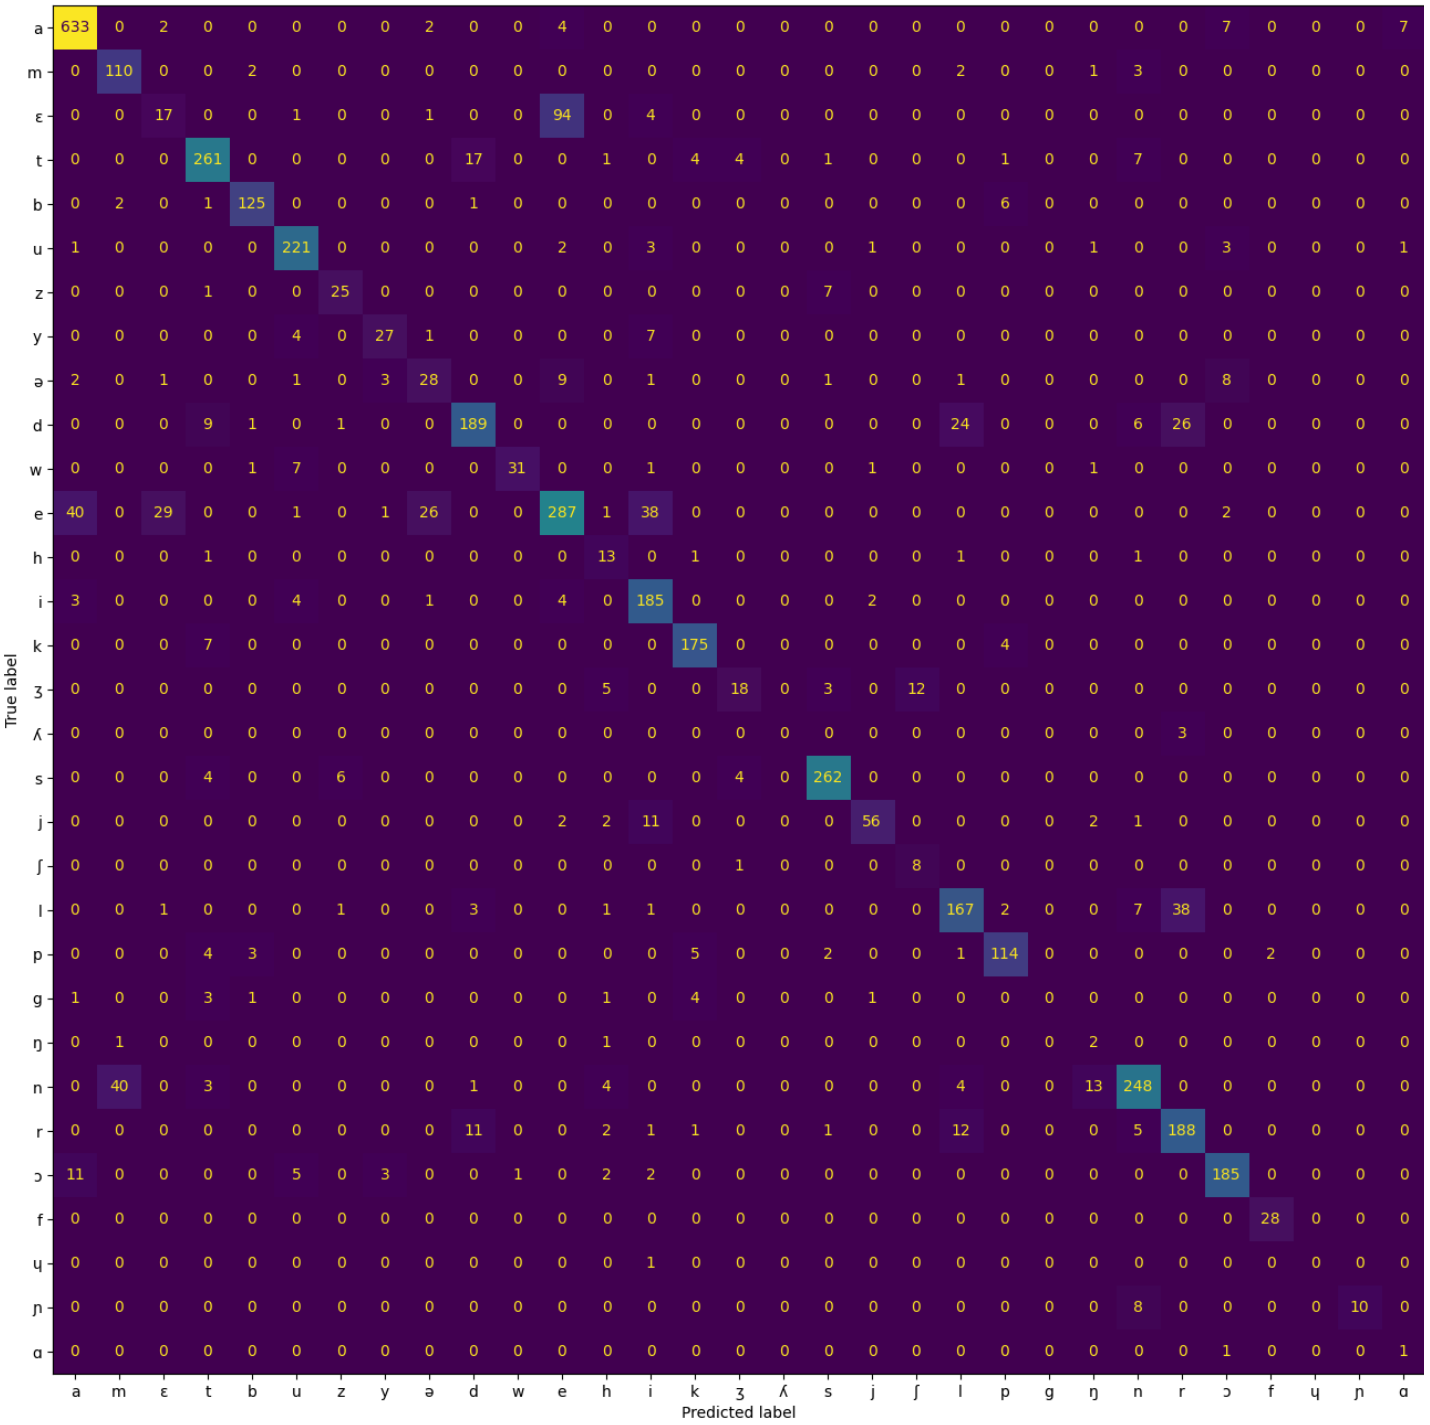


FIGURE 4 - *Matrice de confusion de Wav2Vec2Phoneme sur le corpus de Chants. Les phonèmes sont triés par ordre d'apparition dans la transcription de référence.*

Les matrices de confusion, ainsi que les scores PFER relativement bas, indiquent que les erreurs du modèle concernent le plus souvent des phonèmes proches, tels que par exemple /c/ et /u/, ou /o/ et /a/, /e/ et /i/, etc. Cela illustre la bonne qualité globale du modèle pour la

transcription phonétique de l'occitan, d'autant plus que les substitutions considérées comme des erreurs lors de l'évaluation ne sont pas forcément des hallucinations de la part du modèle, et peuvent s'expliquer par plusieurs facteurs. Premièrement, la transcription de référence étant basée sur l'écrit, les phonèmes considérés comme *true* ne correspondent pas forcément toujours à ce qui est prononcé dans l'audio. Après comparaison manuelle de quelques prédictions avec la transcription de Lo Congrès, nous avons constaté que dans certains cas, les substitutions surviennent dans des cas ambigus, pour lesquels il est difficile de déterminer quelle transcription est la plus correcte entre les deux. Parfois même, la prédiction du modèle correspond mieux à l'audio que la transcription de référence. Bien que ces cas ne constituent pas la majorité, ils sont à prendre en compte lors de l'analyse des résultats, puisqu'ils permettent d'envisager que les performances du modèle sont en réalité légèrement meilleures que celles que nous avons pu mesurer. Les cas où les prédictions du modèle sont effectivement erronées peuvent s'expliquer en partie par la qualité des audios, notamment pour le corpus OcOr et certains audios du corpus Chants. Notre hypothèse est que les résultats sont moins bons pour OcOr et pour le sous-corpus 'Corbefin-Marsac' à cause de la mauvaise qualité des audios, et de la spontanéité des locuteurs (les audios du sous-corpus Corbefin-Marsac sont tirées d'une vidéo et n'ont pas été enregistrés en studio comme le reste du corpus Chants). En effet, Wav2Vec2Phoneme n'a été entraîné que sur des données audios de très bonne qualité, avec un son clair et sans bruits extérieurs. Les données bruitées et plus spontanées que nous lui avons passées constituent un contexte auquel le modèle n'est pas habitué, ce qui dégrade ses performances.

De manière générale, les résultats soulignent l'importance et l'efficacité des méthodes par transfert interlingue. En effet, Wav2Vec2Phoneme obtient un PER de 65% sur des langues inconnues lorsqu'il n'a pas été entraîné sur des langues similaires. En revanche, en ayant été entraîné sur le catalan ainsi que d'autres langues romanes comme le français, l'espagnol ou le portugais, il est capable d'atteindre 20% pour l'occitan bien qu'il n'ait jamais vu cette langue. Ces performances permettent de conclure que le transfert interlingue est une piste intéressante pour adapter des outils de TAL à des langues peu dotées. Cependant, il est important de ne pas oublier que ces résultats ne sont pas exactement comparables aux résultats de l'état de l'art (MultIPA, LoWhIPA), en partie à cause des données de référence qui ne sont pas encore un gold standard, mais également en raison de la taille réduite des corpus.

4.3.2. Analyse des représentations internes

Les métriques utilisées jusqu'ici ne permettent que d'analyser les sorties du modèle, et ne permettent pas d'avoir des informations sur le processus interne. Afin d'observer le modèle plus en profondeur, nous avons réalisé une expérience d'analyse de ses représentations internes. Cette expérience a consisté à faire un clustering sur les états cachés de Wav2Vec2Phoneme pour chaque phonème de la référence, puis à entraîner un classifieur simple (SVM) sur différentes couches d'états cachés afin de déterminer à quel point les informations linguistiques y sont encodées. Nous voulions savoir si, lorsque la prédiction du modèle est erronée, l'information linguistique permettant de distinguer les phonèmes est suffisamment présente dans les états cachés. Pour ce faire, nous avons d'abord extrait les vecteurs cachés produits par le modèle lors de la prédiction, puis nous avons aligné les vecteurs de chaque prédiction avec les phonèmes de référence, grâce à la fonction d'alignement basée sur les distances phonétiques de PanPhon. Afin de visualiser les représentations vectorielles des états cachés, nous avons utilisé l'algorithme t-SNE, qui permet de projeter les vecteurs dans un espace en deux dimensions, tout en préservant au maximum la proximité entre les points. Le clustering des états cachés produits par la dernière couche, avec une projection t-SNE, a donné le graphique suivant :

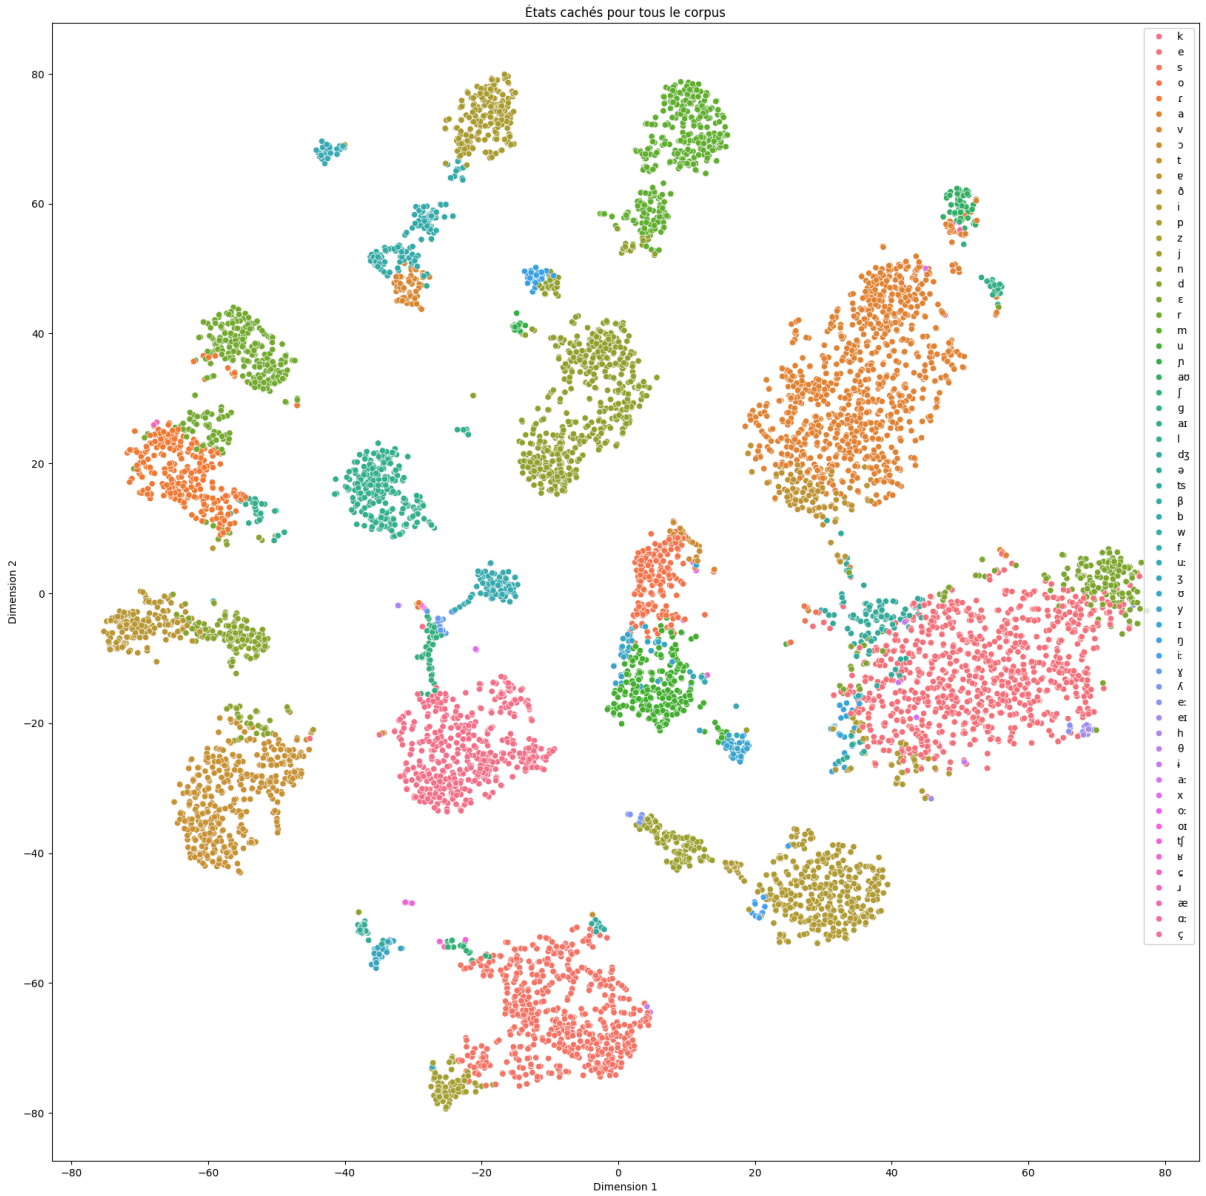


FIGURE 5 - *Clustering (projection TSNE) de la dernière couche d'états cachés pour les prédictions sur le corpus de test de CommonVoice (chaque point correspond à un état caché et chaque couleur correspond au phonème de référence Lo Congrès pour cette prédiction)*

La Figure 5 permet de constater que globalement, les états cachés sont regroupés par phonème, mais le graphique est très large et difficile à interpréter. Afin d'y voir plus clair, nous avons décidé d'afficher les états cachés par paires de phonèmes souvent confondus, c'est-à-dire les /o/ et les /u/, ou les /b/ et /v/ par exemple. L'objectif était de voir si, lors d'une substitution, le problème se situait au niveau de l'encodeur ou du décodeur. Nous avons également affiché les clusters sur des paires de phonèmes qui n'étaient jamais confondus, comme par exemple /k/ et /j/, pour comparer leurs représentations cachées avec celles des phonèmes confondus. Par "souvent confondus", on entend les paires de phonèmes pour lesquelles, lorsque l'un des deux phonèmes était transcrit par Lo Congrès, l'autre était

souvent prédit par le modèle, et vice versa. Afin de voir l'évolution de l'information linguistique dans les états cachés, nous avons affiché un clustering des états cachés sur la dernière couche (la 24ème), puis la 12ème et enfin la première couche d'états cachés. Nous avons obtenu les clustering suivants :

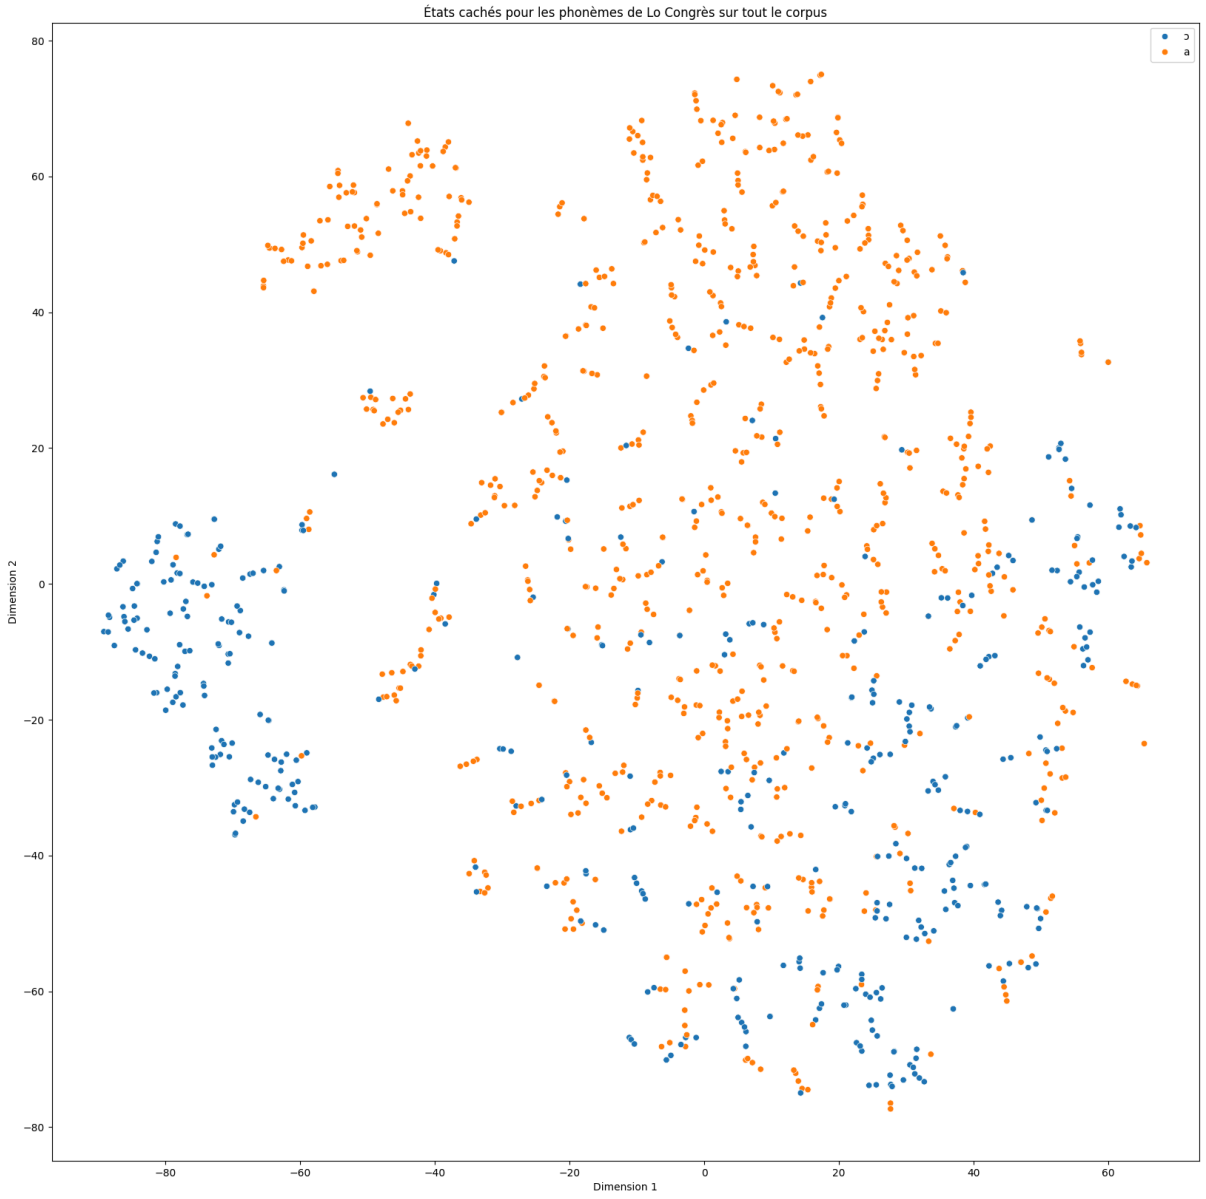


FIGURE 6 - *Clustering (projection TSNE) de la dernière couche d'états cachés pour les phonèmes /a/ et /ɔ/ sur le corpus de test de CommonVoice*

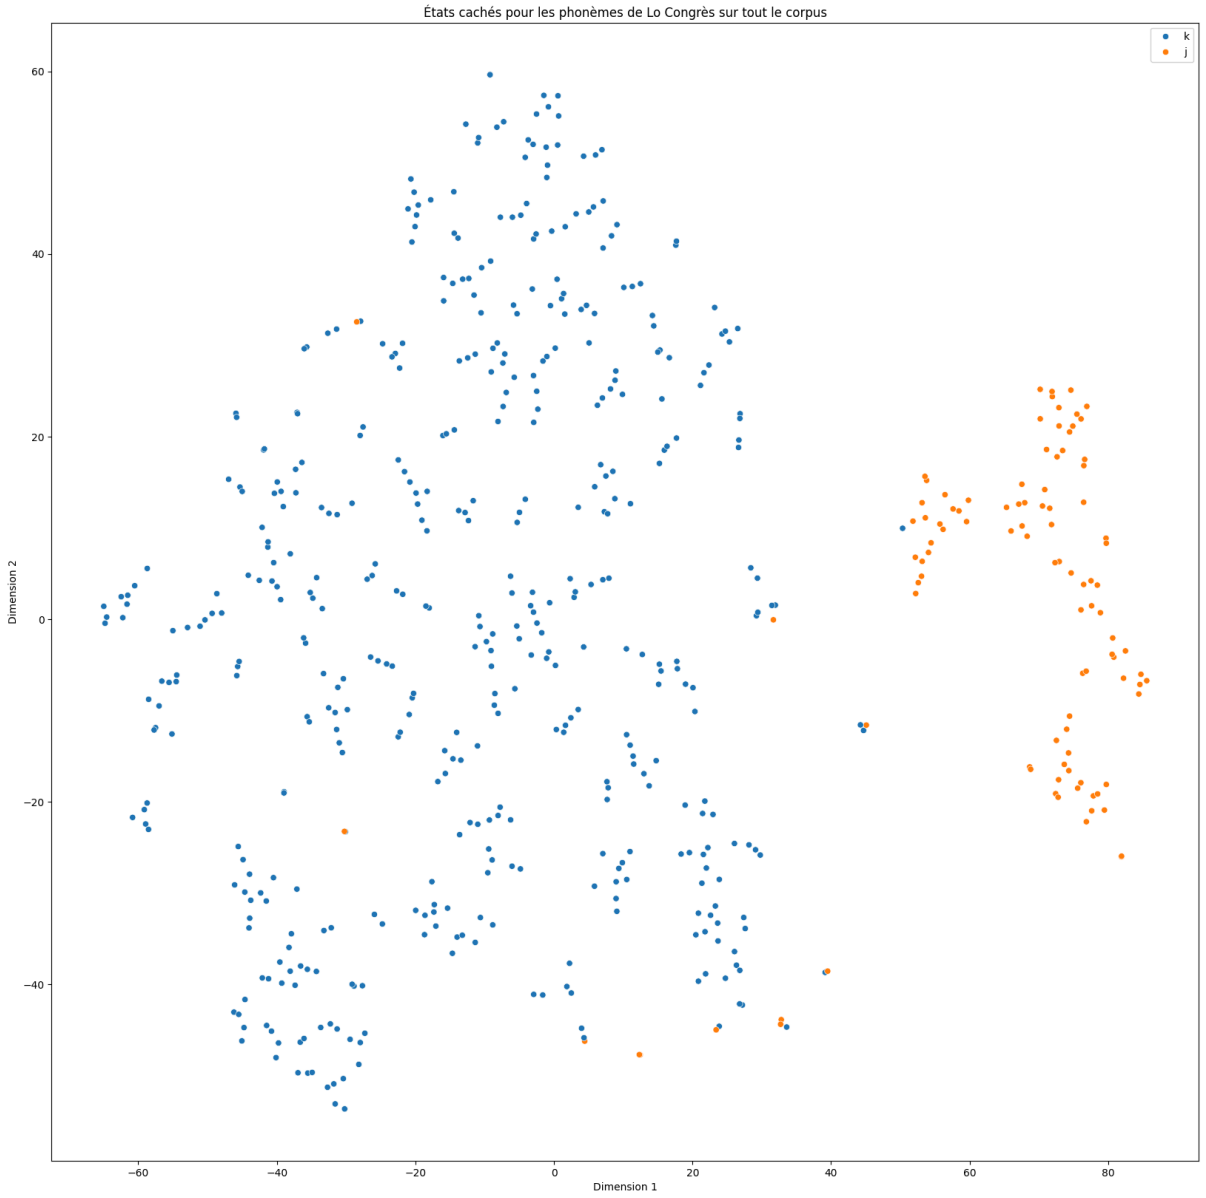


FIGURE 7 - *Clustering (projection TSNE) de la dernière couche d'états cachés pour les phonèmes /k/ et /j/ (qui ne sont jamais confondus par le modèle) sur le corpus de test de CommonVoice*

Pour ne pas surcharger le rapport, nous ne mettons que ces deux exemples (/a/ et /ɔ/, /k/ et /j/), mais nous avons testé ce clustering pour de nombreuses paires de phonèmes et pouvons ainsi attester que ces cas sont globalement représentatifs de l'ensemble des cas. Les représentations de la dernière couche sont affichées dans les Figures 6 et 7, et les représentations de la douzième et de la première couches sont représentées sur les Figures 8, 9, 10, 11, en annexe de ce rapport. On constate que, dès la première couche et selon la projection TSNE, l'information phonétique permettant au modèle de distinguer des phonèmes

très éloignés comme /k/ et /j/ est déjà encodée. La représentation des deux phonèmes dans l'espace vectoriel ne varie que très peu au fil des couches, puisqu'elle est déjà bien ancrée au départ. En revanche, l'affichage des états cachés pour des phonèmes proches et souvent confondus comme /a/ et /ɔ/ révèle que, même dans la dernière couche, les phonèmes sont très proches dans l'espace vectoriel, ce qui explique les erreurs fréquentes du modèle entre ces deux phonèmes. On constate néanmoins une séparation progressive des représentations entre la première et la dernière couche, même si elles restent proches. Dans la continuité de cette tâche d'évaluation interne de notre outil, et étant donné que la projection en 2D de TSNE tronque nécessairement les représentations, nous avons décidé d'entraîner et de tester un classifieur simple sur les couples "vecteur caché - phonème Lo Congrès" , toujours dans l'objectif de déterminer quelles informations linguistiques sont encodées. Pour cette tâche de classification, nous avons passé les vecteurs de la dernière couche à un SVM et lui avons demandé de prédire les phonèmes de référence. Le SVM a obtenu des résultats satisfaisants, avec une accuracy globale de 0.89 et une F1-mesure pondérée de 0.88. Le tableau suivant présente les résultats obtenus sur les 7806 couples vecteur-phonème de l'ensemble de test de CommonVoice :

Phonème	**Précision**	**Rappel**	**F1-score**	**Support**
/a/	0.89	0.90	0.90	865
/b/	0.92	0.92	0.92	201
/d/	0.93	0.94	0.94	304
/e/	0.88	0.92	0.90	1196
/f/	0.91	0.90	0.91	48
/g/	0.81	0.87	0.84	71
/h/	0.00	0.00	0.00	6
/i/	0.84	0.90	0.87	352
/j/	0.63	0.65	0.64	102
/k/	0.94	0.97	0.96	464
/l/	0.88	0.97	0.92	197
/m/	0.91	0.96	0.93	301
/n/	0.92	0.94	0.93	434
/o/	0.00	0.00	0.00	4
/p/	0.91	0.93	0.92	206
/r/	0.95	0.97	0.96	557
/s/	0.91	0.96	0.93	606
/t/	0.96	0.90	0.93	476
/u/	0.82	0.92	0.87	333
/w/	0.81	0.71	0.76	104
/y/	0.88	0.55	0.68	129
/z/	0.78	0.57	0.66	95
Accuracy	-	-	**0.89**	7806
Macro avg	0.72	0.70	0.70	7806
Weighted avg	0.88	0.89	0.88	7806

TABLE 3 - *Résultats du SVM sur les phonèmes de référence de l'ensemble de test de CommonVoice*

Les seuls phonèmes pour lesquels le score descend en dessous de 0.80 sont ceux qui sont le moins représentés : le score sur les phonèmes qui ont entre 90 et 110 occurrences se situe entre 0.64 et 0.91, et les phonèmes pour lesquels le score est à 0.00 (donc qui ne sont jamais prédits par le SVM) sont ceux qui ont moins de 10 occurrences sur les 7806. Ces résultats montrent qu'un classifieur relativement simple est capable de retrouver la grande majorité des phonèmes à partir des représentations vectorielles encodées dans la dernière couche du modèle. Les états cachés de la dernière couche de Wav2Vec2Phoneme semblent donc encoder l'information linguistique pertinente pour distinguer les phonèmes en occitan. Les erreurs observées lors de la prédiction peuvent provenir de la phase de décodage plutôt que de l'encodage. L'ajout de contraintes au prédicteur le suggérait également ; une adaptation de la sortie spécifique à l'occitan pourrait être suffisante pour que le modèle soit adapté à cette langue. En montrant que les contrastes phonétiques de l'occitan semblent être bien encodés, cette expérience nous permet d'envisager d'autres pistes pour adapter le modèle à l'occitan plutôt qu'un fine-tuning.

Conclusion et discussions

Malgré l'absence de l'occitan parmi les langues d'entraînement de Wav2Vec2Phoneme, les performances du modèle sur cette langue sont encourageantes. Les scores observés sur les différents corpus mettent en évidence plusieurs choses. Premièrement, le transfert interlingue permet à un modèle entraîné sur plusieurs langues romanes de produire des transcriptions phonétiques globalement fiables en occitan. Ensuite, les résultats ont permis de mettre en évidence la possibilité d'utiliser différents types de données pour constituer des corpus. Le test du modèle sur le corpus de chants a notamment permis de démontrer l'utilisabilité d'un tel type de données audios pour une tâche de transcription phonétique. La comparaison des résultats entre les différents a aussi permis de souligner une des limites majeures du modèle : la dépendance de ses performances à la qualité de l'audio. L'exploration des techniques d'alignement a montré que fonder l'alignement sur les propriétés phonétiques rend l'évaluation plus pertinente et renvoie des résultats plus fiables qu'un simple alignement en fonction de la distance de Levenshtein. Enfin, l'analyse des représentations internes du modèle suggère que l'information linguistique nécessaire à la distinction des phonèmes de l'occitan est déjà encodée dans les états cachés. Ces observations permettent de conclure qu'une adaptation des sorties du modèle peut être une piste

envisageable pour améliorer les performances du modèle sur l'occitan, plutôt qu'un fine-tuning complet.

Le projet étant à son commencement pour l'occitan, les travaux réalisés lors de ce stage ouvrent la voie à plusieurs perspectives d'amélioration. L'une des principales perspectives à envisager est l'amélioration des données de référence. Concernant le corpus Occiton2, pour lequel les transcriptions n'étaient pas utilisables, un travail de "traduction" de la convention utilisée pour les transcriptions phonétiques du corpus vers l'API est prévu. L'idée sera de traduire quelques transcriptions disponibles vers l'API, et d'entraîner un modèle capable de reproduire cette traduction sur toutes les transcriptions du corpus. Ainsi, on obtiendrait un jeu de données avec des transcriptions de références encore plus fiables que celles de Lo Congrès, puisqu'elles auront été annotées manuellement à partir de l'audio avant d'être traduites en API. Trouver des annotateurs humains pour produire une transcription phonétique de référence directement à partir des audios serait extrêmement intéressant pour notre tâche, mais difficile à implémenter. Une seconde piste serait, une fois le gold standard obtenu, de procéder à de l'augmentation de données, par exemple en changeant la qualité, la hauteur de la voix, etc. De plus, comme nous avons vu que les chants sont utilisables pour cette tâche, il serait intéressant d'en récupérer plus pour pouvoir constituer un plus grand corpus.

D'un point de vue personnel, les missions que j'ai menées au cours de ce stage étaient très variées et m'ont permis d'élargir mon expérience dans différents domaines du TAL : j'ai eu l'occasion de constituer un corpus annoté, de mettre en place une pipeline de traitement de données et de transcription phonétique, d'explorer différentes stratégies d'alignement des prédictions avec la référence, d'évaluer et analyser les résultats d'un modèle de transcription, jusqu'à étudier et analyser les représentations internes d'un modèle. Ces missions m'ont en outre permis de mieux me familiariser à la fois avec les enjeux spécifiques à l'ASR, et avec les enjeux liés aux langues peu dotées. De manière générale, mon stage m'a aidée à développer une plus grande autonomie dans le travail en TAL, en me permettant de mettre en pratique et d'enrichir de nombreuses compétences et connaissances théoriques qui m'ont été enseignées au cours du Master TAL. Ce stage m'a également permis de gagner en assurance et d'être plus sûre de moi lors de la prise de décisions.

D'un point de vue pratique, le stage m'a aussi donné l'occasion de mettre en place des "bonnes pratiques" et d'acquérir de bonnes habitudes de code. En effet, au début de mon

stage, le code que j'écrivais n'était pas structuré, et j'avais tendance à n'utiliser qu'un seul notebook dans lequel j'écrivais toutes mes fonctions. De même, j'avais tendance à multiplier les boucles "inutiles", ou au contraire à répéter une même logique de nombreuses fois sans créer de boucle, ce qui rendait mes scripts lourds et difficiles à lire. Au cours du stage, et au fil des réunions hebdomadaires avec mes encadrants, j'ai progressivement mis en place une pipeline organisée en plusieurs scripts ayant chacun une fonction distincte, et quelques notebooks de test. J'ai acquis des réflexes de programmation, comme notamment ajouter une docstring pour expliquer ce que fait un script, ou organiser mon code en plusieurs fichiers selon l'utilité de chaque script. J'ai également créé une page Github sur laquelle j'ai déposé les scripts que j'ai créés.[15]

Enfin, les événements tels que les conférences, séminaires, réunions et groupes de travail, auxquels j'ai eu l'occasion de participer très régulièrement durant mon stage, se sont révélés très formateurs en ce qu'ils m'ont permis de faire mes premiers pas dans le monde du travail, dans un contexte hors-académique. L'équipe dans laquelle j'ai été intégrée a fait preuve d'une grande bienveillance à mon égard, et l'accueil chaleureux que j'ai reçu tout au long de mon stage a grandement contribué à mon épanouissement, tant au niveau professionnel que personnel.

[15] https://github.com/Manon09825/Traitement-automatique-de-l-oral---occitan

Bibliographie

Baevski, A., Zhou, H., Mohamed, A., & Auli, M. (2020). *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations* (arXiv:2006.11477). arXiv. https://doi.org/10.48550/arXiv.2006.11477

Gao, H., Ni, J., Zhang, Y., Qian, K., Chang, S., & Hasegawa-Johnson, M. (2021). *Zero-Shot Cross-Lingual Phonetic Recognition with External Language Embedding*. 1304–1308. https://doi.org/10.21437/Interspeech.2021-1843

Morcillo, I., Leturia, I., Corral, A., Sarasola, X., Barret, M., Séguier, A., & Dazéas, B. (2024). Automatic Speech Recognition for Gascon and Languedocian Variants of Occitan. In N. Calzolari, M.-Y. Kan, V. Hoste, A. Lenci, S. Sakti, & N. Xue (Eds), *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)* (pp. 1969–1978). ELRA and ICCL. https://aclanthology.org/2024.lrec-main.177/

Mortensen, D. R., Littell, P., Bharadwaj, A., Goyal, K., Dyer, C., & Levin, L. (2016). PanPhon: A Resource for Mapping IPA Segments to Articulatory Feature Vectors. In Y. Matsumoto & R. Prasad (Eds), *Proceedings of COLING 2016, the 26th International Conference on Computational Linguistics: Technical Papers* (pp. 3475–3484). The COLING 2016 Organizing Committee. https://aclanthology.org/C16-1328/

Radford, A., Kim, J. W., Xu, T., Brockman, G., Mcleavey, C., & Sutskever, I. (2023). Robust Speech Recognition via Large-Scale Weak Supervision. *Proceedings of the 40th International Conference on Machine Learning*, 28492–28518. https://proceedings.mlr.press/v202/radford23a.html

Suchardt, J. L., El-Shazli, H., & Cassotti, P. (2025). Towards Language-Agnostic STIPA: Universal Phonetic Transcription to Support Language Documentation at Scale. In C. Christodoulopoulos, T. Chakraborty, C. Rose, & V. Peng (Eds), *Proceedings of the*

2025 Conference on Empirical Methods in Natural Language Processing (pp. 31423–31439). Association for Computational Linguistics. https://doi.org/10.18653/v1/2025.emnlp-main.1600

Taguchi, C., Sakai, Y., Haghani, P., & Chiang, D. (2023). *Universal Automatic Phonetic Transcription into the International Phonetic Alphabet* (arXiv:2308.03917). arXiv. https://doi.org/10.48550/arXiv.2308.03917

Xu, Q., Baevski, A., & Auli, M. (2021). *Simple and Effective Zero-shot Cross-lingual Phoneme Recognition* (arXiv:2109.11680). arXiv. https://doi.org/10.48550/arXiv.2109.11680

Annexes

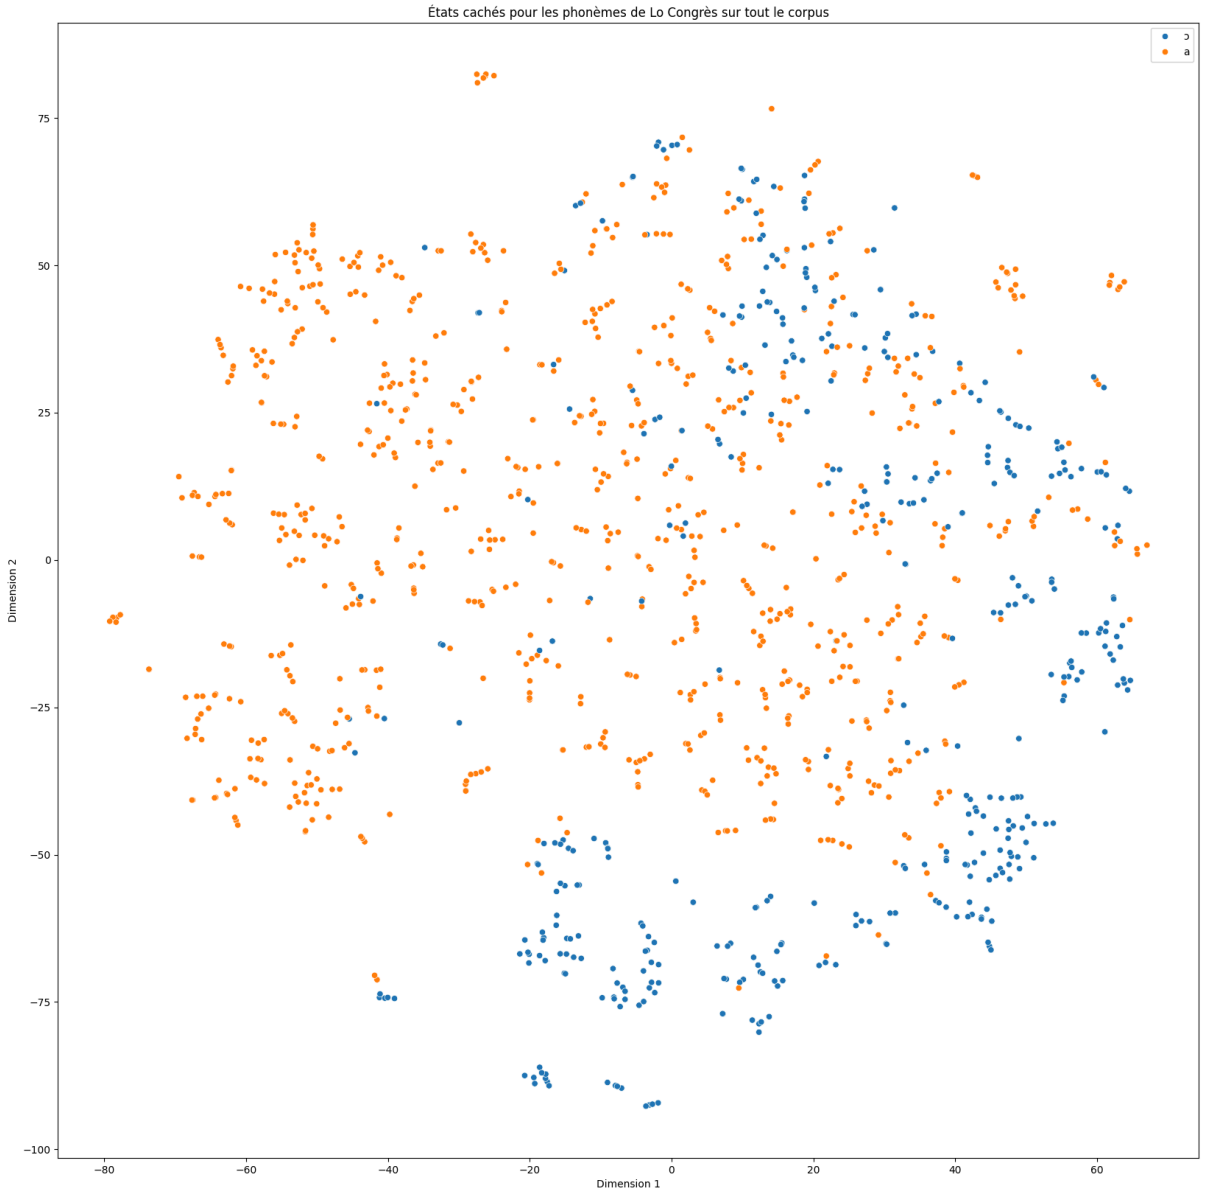


FIGURE 8 - *Clustering de la douzième couche d'états cachés pour les phonèmes /a/ et /ɔ/ sur le corpus de test de CommonVoice*

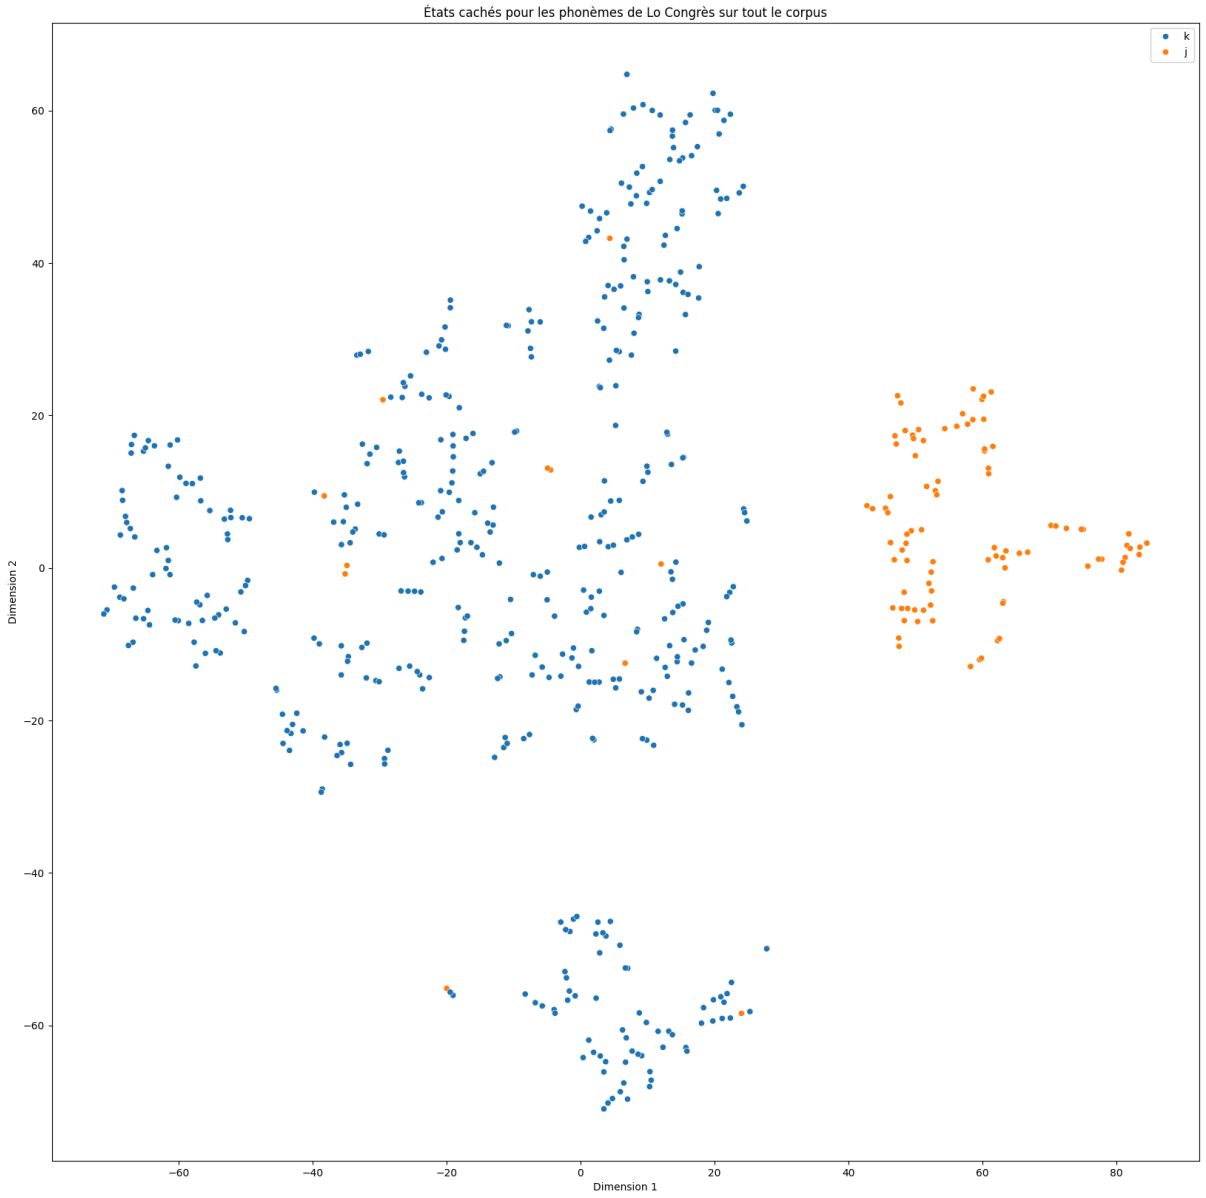


FIGURE 9 - *Clustering de la douzième couche des états cachés pour les phonèmes /k/ et /j/ sur le corpus de test de CommonVoice*

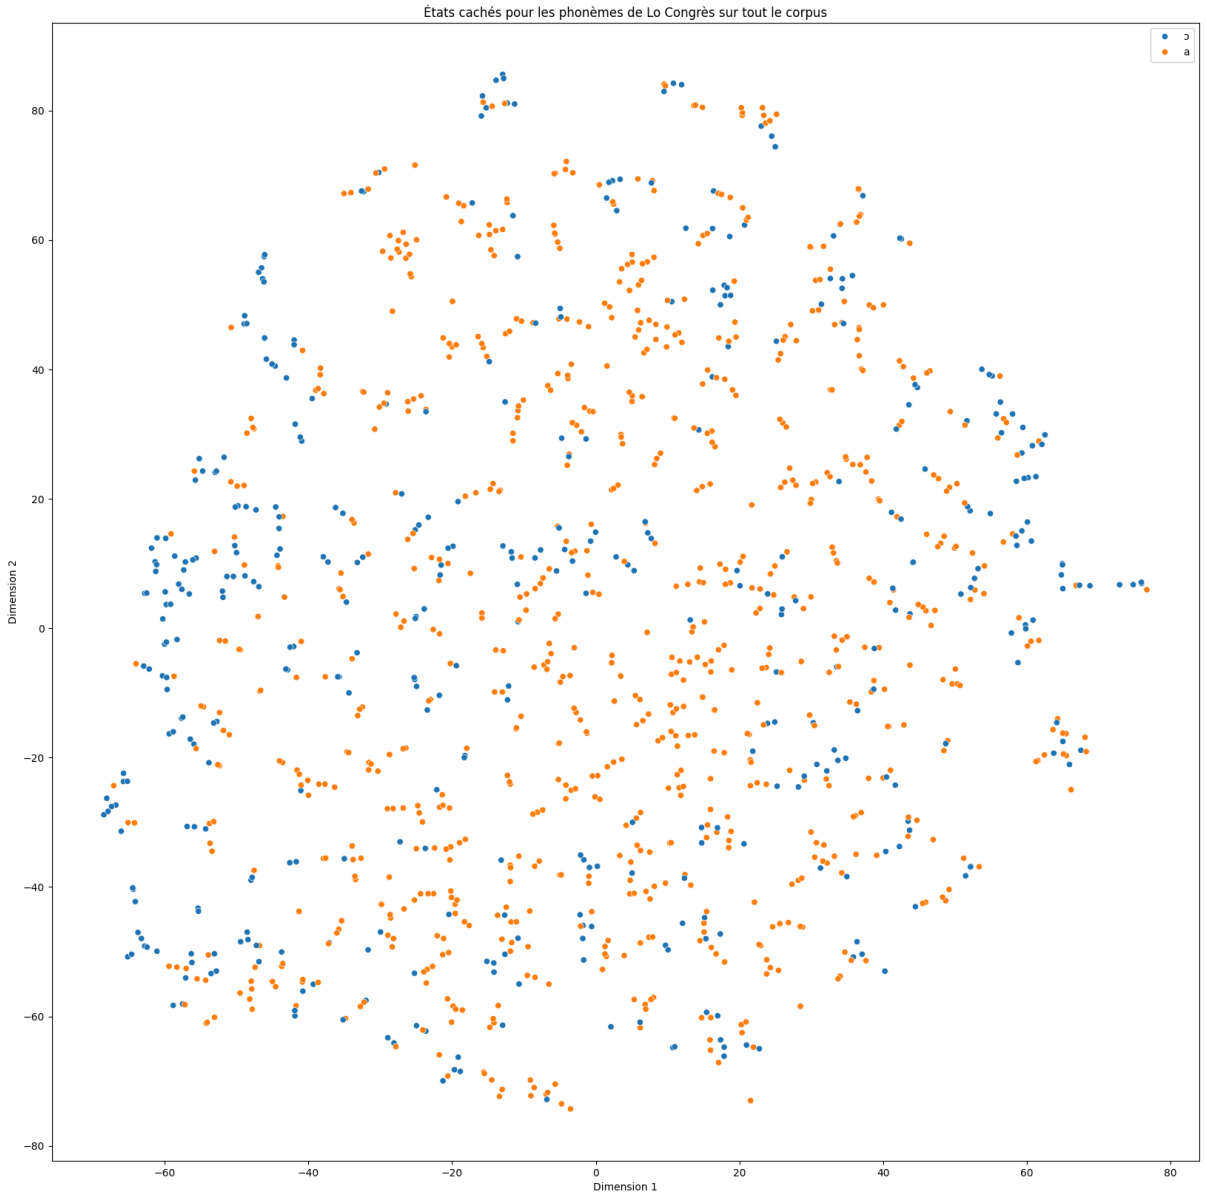


FIGURE 10 - *Clustering de la première couche d'états cachés pour les phonèmes /a/ et /ɔ/ sur le corpus de test de CommonVoice*

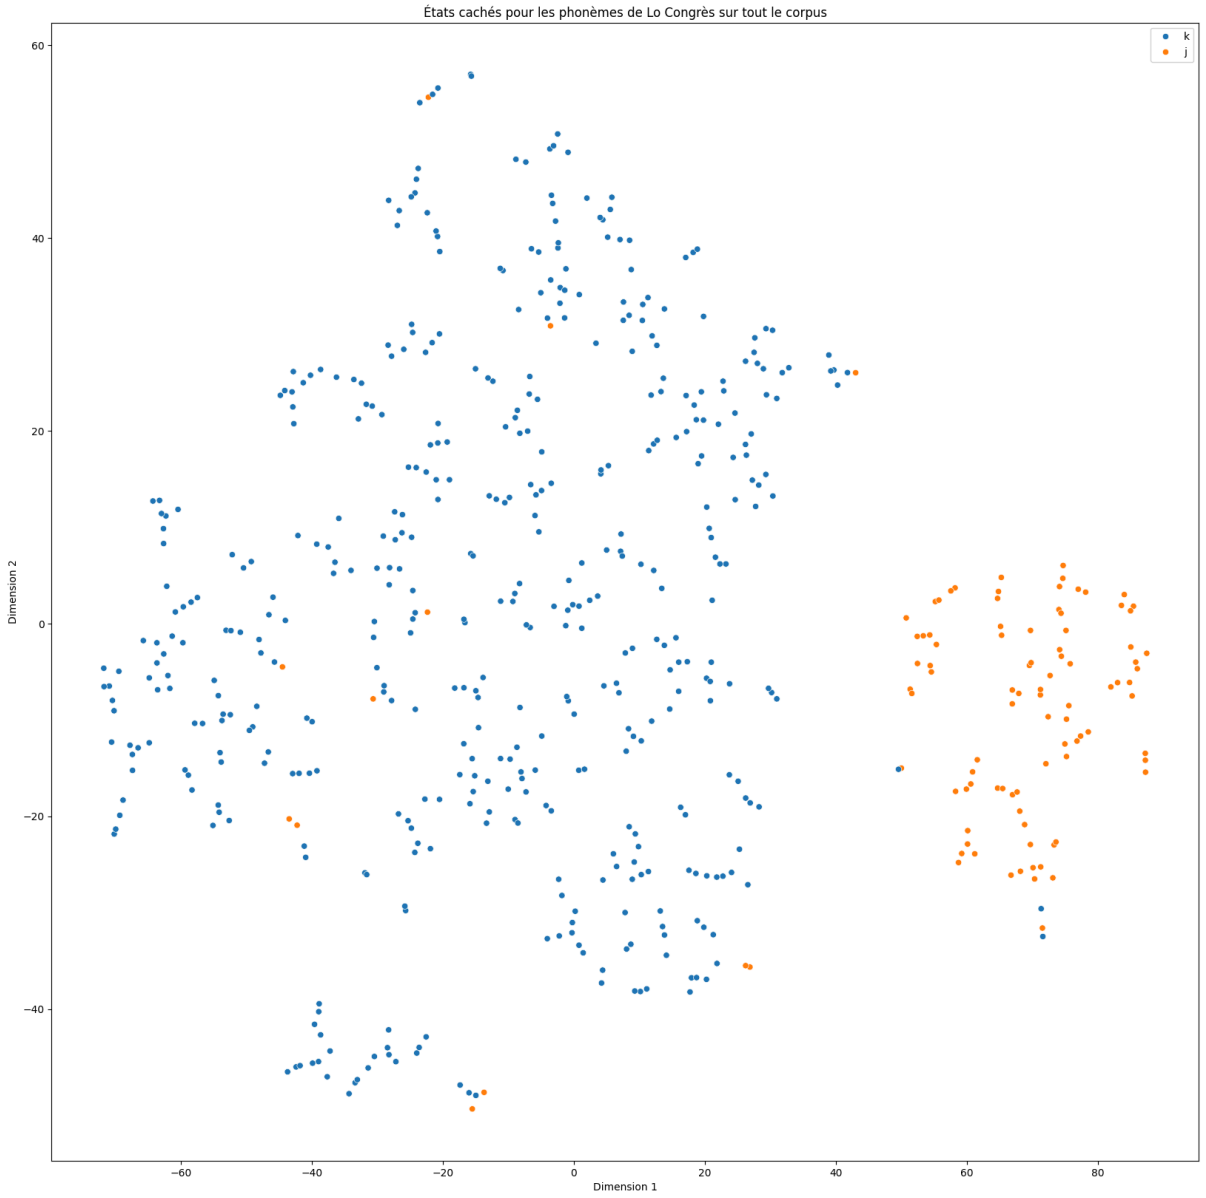
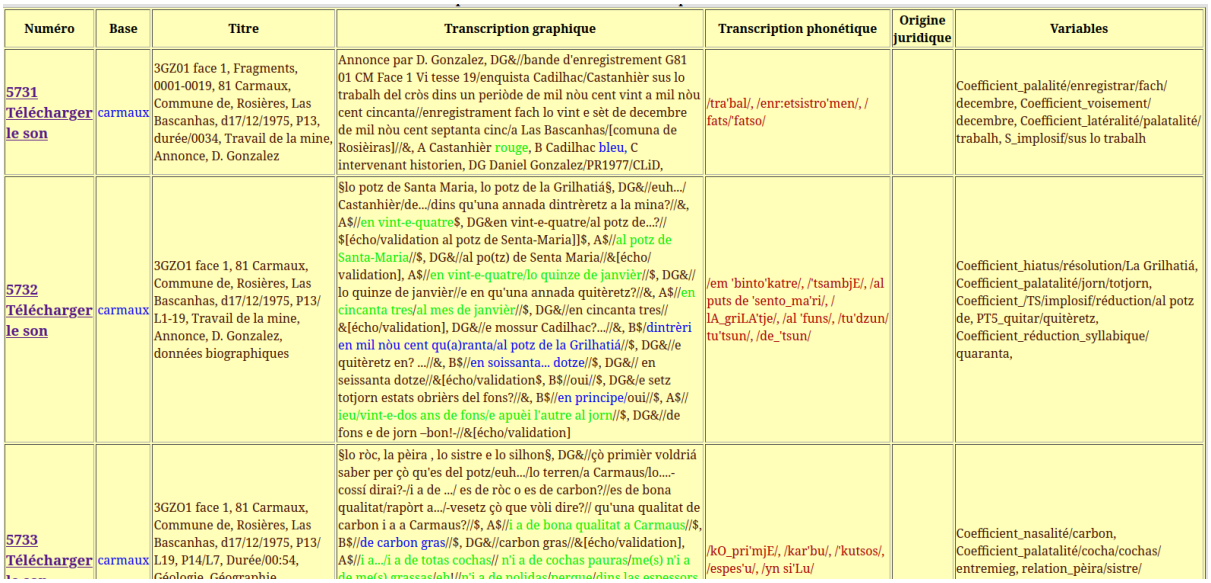


FIGURE 11 - *Clustering de la première couche d'états cachés pour les phonèmes /k/ et /j/ sur le corpus de test de CommonVoice*



Numéro	Base	Titre	Transcription graphique	Transcription phonétique	Origine juridique	Variables
5731 Télécharger le son	carmaux	3GZ01 face 1, Fragments, 0001-0019, 81 Carmaux, Commune de, Rosières, Las Bascanhas, d17/12/1975, P13, durée/0034, Travail de la mine, Annonce, D. Gonzalez	Annonce par D. Gonzalez, DG&//bande d'enregistrement G81 01 CM Face 1 Vi tesse 19/enquista Cadilhac/Castanhièr sus lo trabalh del crós dins un periòde de mil nòu cent vint a mil nòu cent cincanta//enregistrament fach lo vint e sèt de decembre de mil nòu cent septanta cinc/a Las Bascanhas/[comuna de Rosièiras]//&, A Castanhièr rouge, B Cadilhac bleu, C intervenant historien, DG Daniel Gonzalez/PR1977/CLiD,	/tra'bal/, /enr:etsistro'men/, /fats/'fatso/		Coefficient_palalité/enregistrar/fach/decembre, Coefficient_voisement/decembre, Coefficient_latéralité/palatalité/trabalh, S_implosif/sus lo trabalh
5732 Télécharger le son	carmaux	3GZO1 face 1, 81 Carmaux, Commune de, Rosières, Las Bascanhas, d17/12/1975, P13/L1-19, Travail de la mine, Annonce, D. Gonzalez, données biographiques	§lo potz de Santa Maria, lo potz de la Grilhatiá§, DG&//euh.../Castanhièr/de.../dins qu'una annada dintrèretz a la mina?//&, A$//en vint-e-quatre$, DG&en vint-e-quatre/al potz de...?//$[écho/validation al potz de Senta-Maria]]$, A$//al potz de Santa-Maria//$, DG&//al po(tz) de Senta Maria//&[écho/validation], A$//en vint-e-quatre/lo quinze de janvièr//$, DG&//lo quinze de janvièr//e en qu'una annada quitèretz?//&, A$//en cincanta tres/al mes de janvièr//$, DG&//en cincanta tres//&[écho/validation], DG&//e mossur Cadilhac?...//&, B$/dintrèri en mil nòu cent qu(a)ranta/al potz de la Grilhatiá//$, DG&//e quitèretz en? ...//&, B$//en soissanta... dotze//$, DG&// en seissanta dotze//&[écho/validation$, B$//oui//$, DG&/e setz totjorn estats obrièrs del fons?//&, B$//en principe/oui//$, A$//ieu/vint-e-dos ans de fons/e apuèi l'autre al jorn//$, DG&//de fons e de jorn –bon!-//&[écho/validation]	/em 'binto'katre/, /'tsambjE/, /al puts de 'sento_ma'ri/, /lA_griLA'tje/, /al 'funs/, /tu'dzun/ tu'tsun/, /de_'tsun/		Coefficient_hiatus/résolution/La Grilhatiá, Coefficient_palatalité/jorn/totjorn, Coefficient_/TS/implosif/réduction/al potz de, PT5_quitar/quitèretz, Coefficient_réduction_syllabique/quaranta,
5733 Télécharger le son	carmaux	3GZO1 face 1, 81 Carmaux, Commune de, Rosières, Las Bascanhas, d17/12/1975, P13/L19, P14/L7, Durée/00:54, Géologie, Géographie	§lo ròc, la pèira , lo sistre e lo silhon§, DG&//çò primièr voldriá saber per çò qu'es del potz/euh.../lo terren/a Carmaus/lo....-cossí dirai?-/i a de .../ es de ròc o es de carbon?//es de bona qualitat/rapòrt a.../-vesetz çò que vòli dire?// qu'una qualitat de carbon i a a Carmaus?//$, A$//i a de bona qualitat a Carmaus//$, B$//de carbon gras//$, DG&//carbon gras//&[écho/validation], A$//i a.../i a de totas cochas// n'i a de cochas pauras/me(s) n'i a de me(s) grassas/eh!//n'i a de polidas/perque/dins las espessors	/kO_pri'mjE/, /kar'bu/, /'kutsos/, /espes'u/, /yn si'Lu/		Coefficient_nasalité/carbon, Coefficient_palatalité/cocha/cochas/entremieg, relation_pèira/sistre/

FIGURE 12 - *Exemple de l'interface sur laquelle sont disponibles les audios et transcriptions du corpus Occiton2*[16]

[16] http://occiton.free.fr/sons/occiton2/occiton2.php